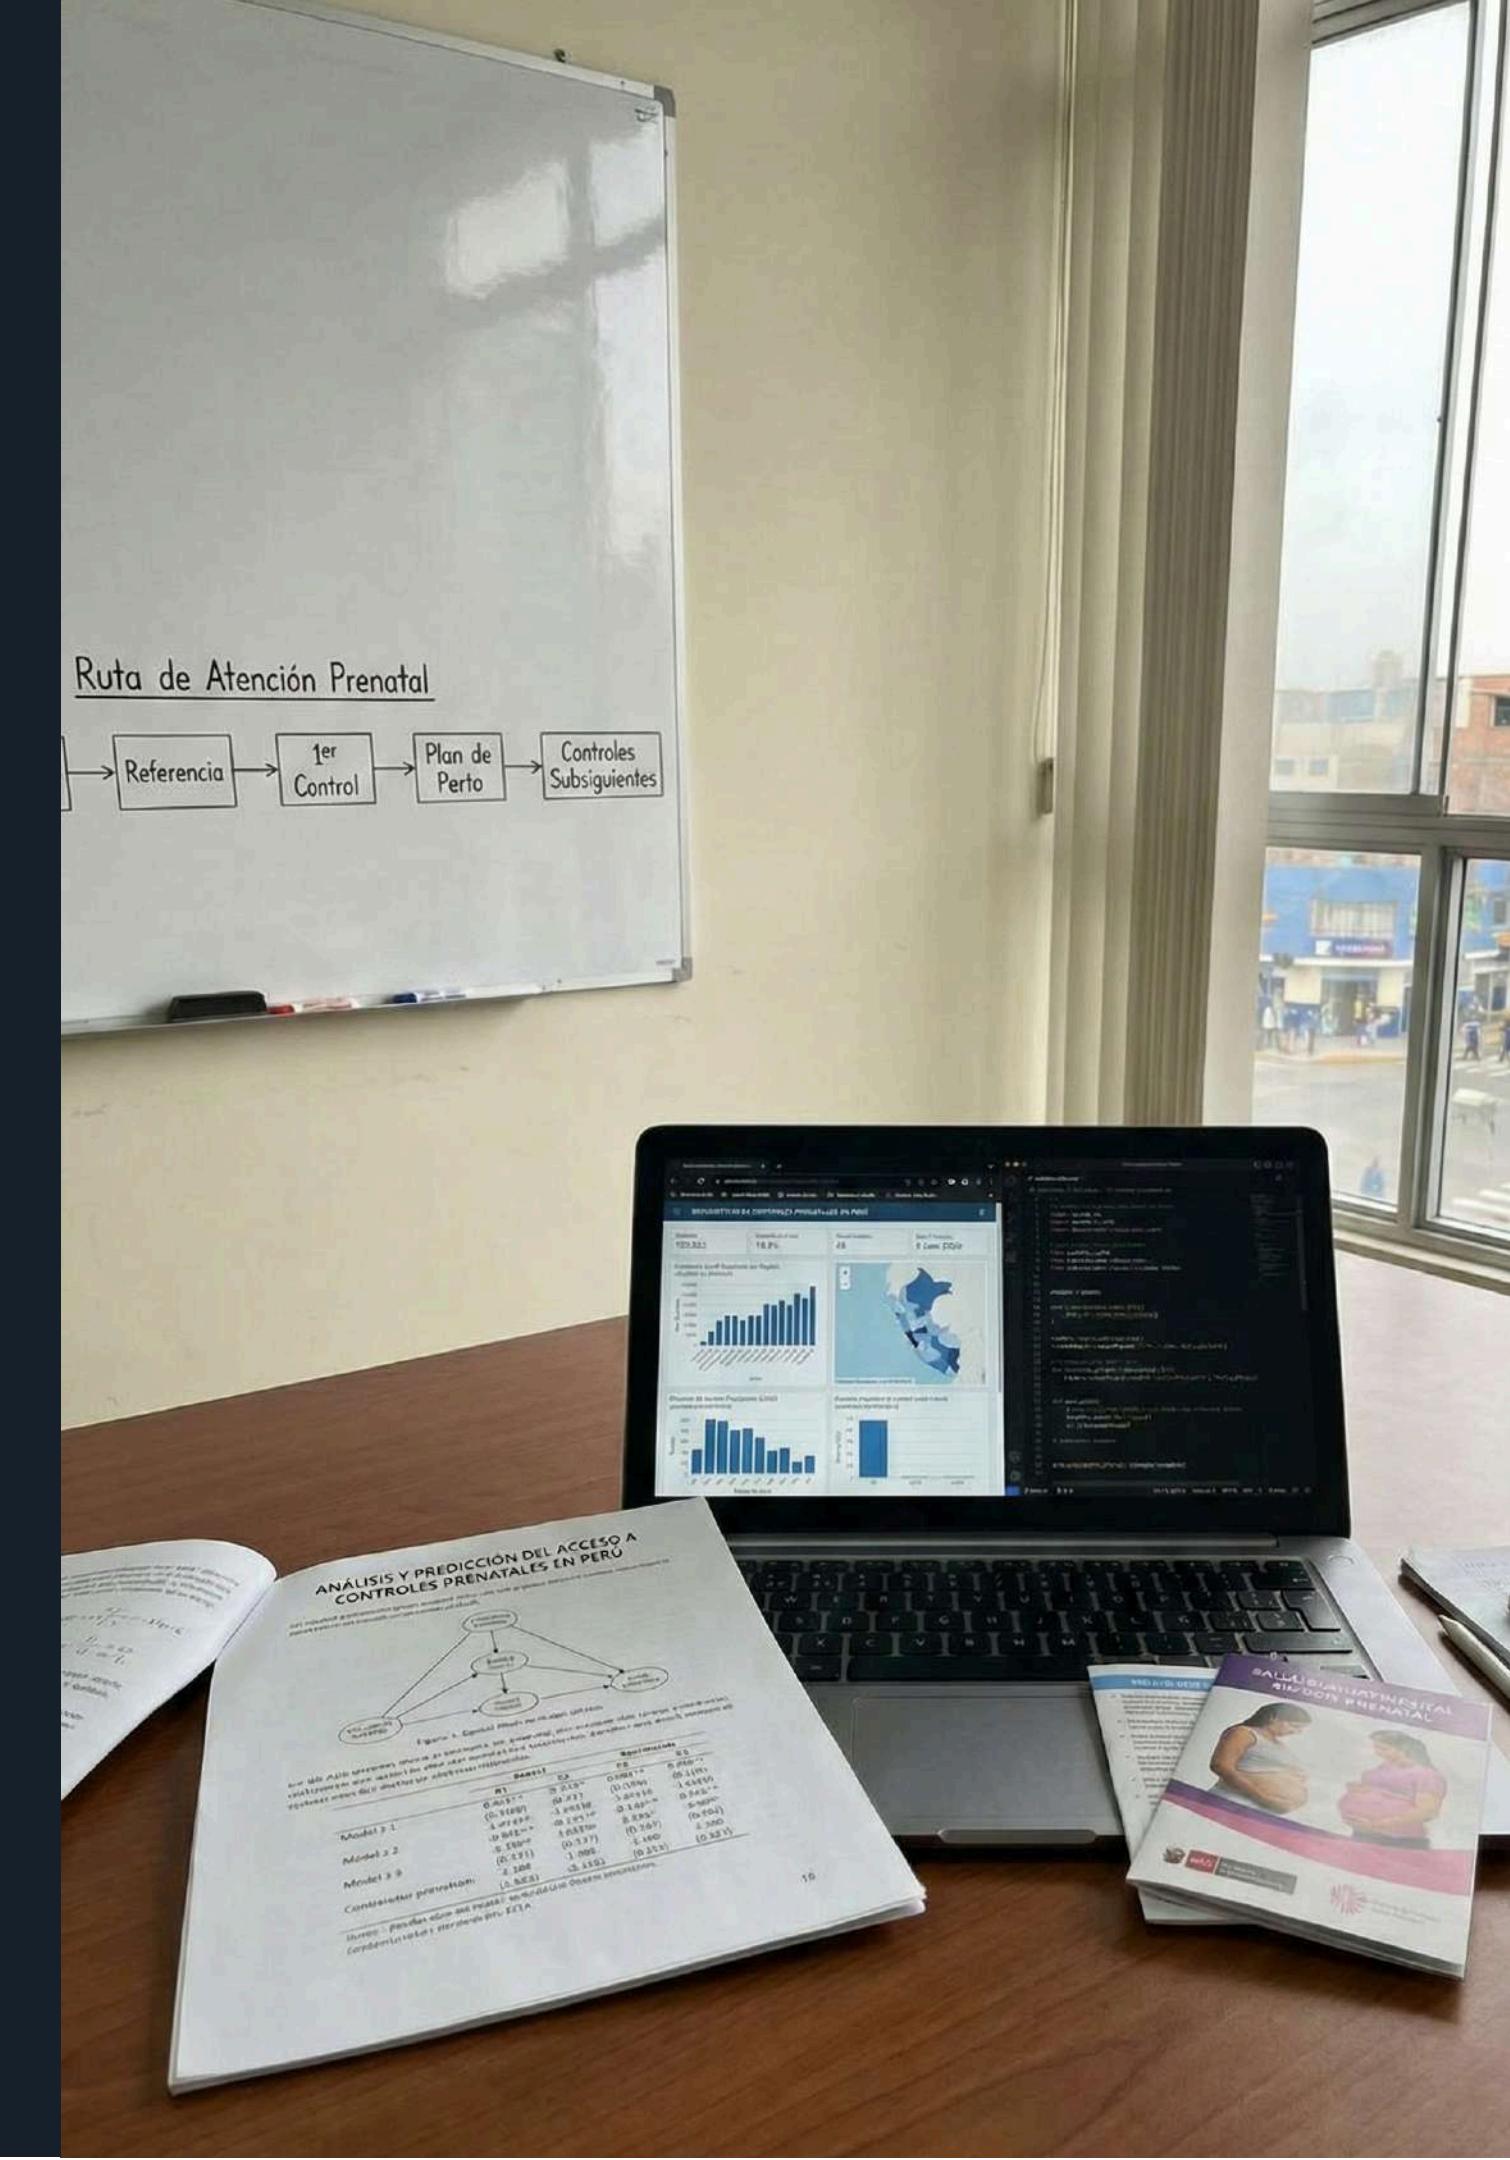


Análisis y Predicción del Acceso a Controles Prenatales en Perú.

INTEGRANTES:

Fabricio Calle Cardoza \\ Bianca Nicole Jimenez Vargas \\
Aracely Lalupu Lalupu \\ Jose Alonso Naira Carmen.



MOTIVACIÓN

- La atención prenatal ayuda a prevenir riesgos durante el embarazo y garantiza un parto más seguro.
- En el Perú se recomiendan 6 o más controles para una atención adecuada.
- No todas las madres alcanzan este estándar, especialmente en zonas rurales y en hogares con menos recursos.
- La educación puede influir en la información, las decisiones y la búsqueda de atención de salud.

¿CÓMO SE RELACIONA EL NIVEL EDUCATIVO DE LA MADRE CON EL ACCESO A CONTROLES PRENATALES ADECUADOS EN EL PERÚ?

Hipótesis: Mayor nivel educativo aumenta la probabilidad de recibir un control prenatal adecuado.



DATA

Fuente de datos: ENDES (2018 - 2023)

Variables:

- Control Prenatal Adecuado: Variable dependiente.
- Edad de la Madre
- Nivel Educativo de la Madre
- Quintil de Riqueza
- Ubicación geográfica (urbano/rural)
- Región

	prenatal_adecuado	Edad	Nivel_riqueza	Urbano	SREGION	educacion_grupo	
0	1	42.0	3.0	1	3	2	
1	0	20.0	2.0	1	3	3	
2	0	25.0	2.0	1	3	3	
3	1	35.0	5.0	1	3	3	
4	1	22.0	5.0	1	3	2	
5	0	48.0	5.0	1	3	3	
6	1	26.0	2.0	1	3	2	
7	0	39.0	4.0	1	3	3	
8	1	18.0	3.0	1	3	2	
9	1	23.0	1.0	1	3	2	

TRABAJO 1:

Exploración de datos (EDA)



Figura 1: Mapa de Missing Values

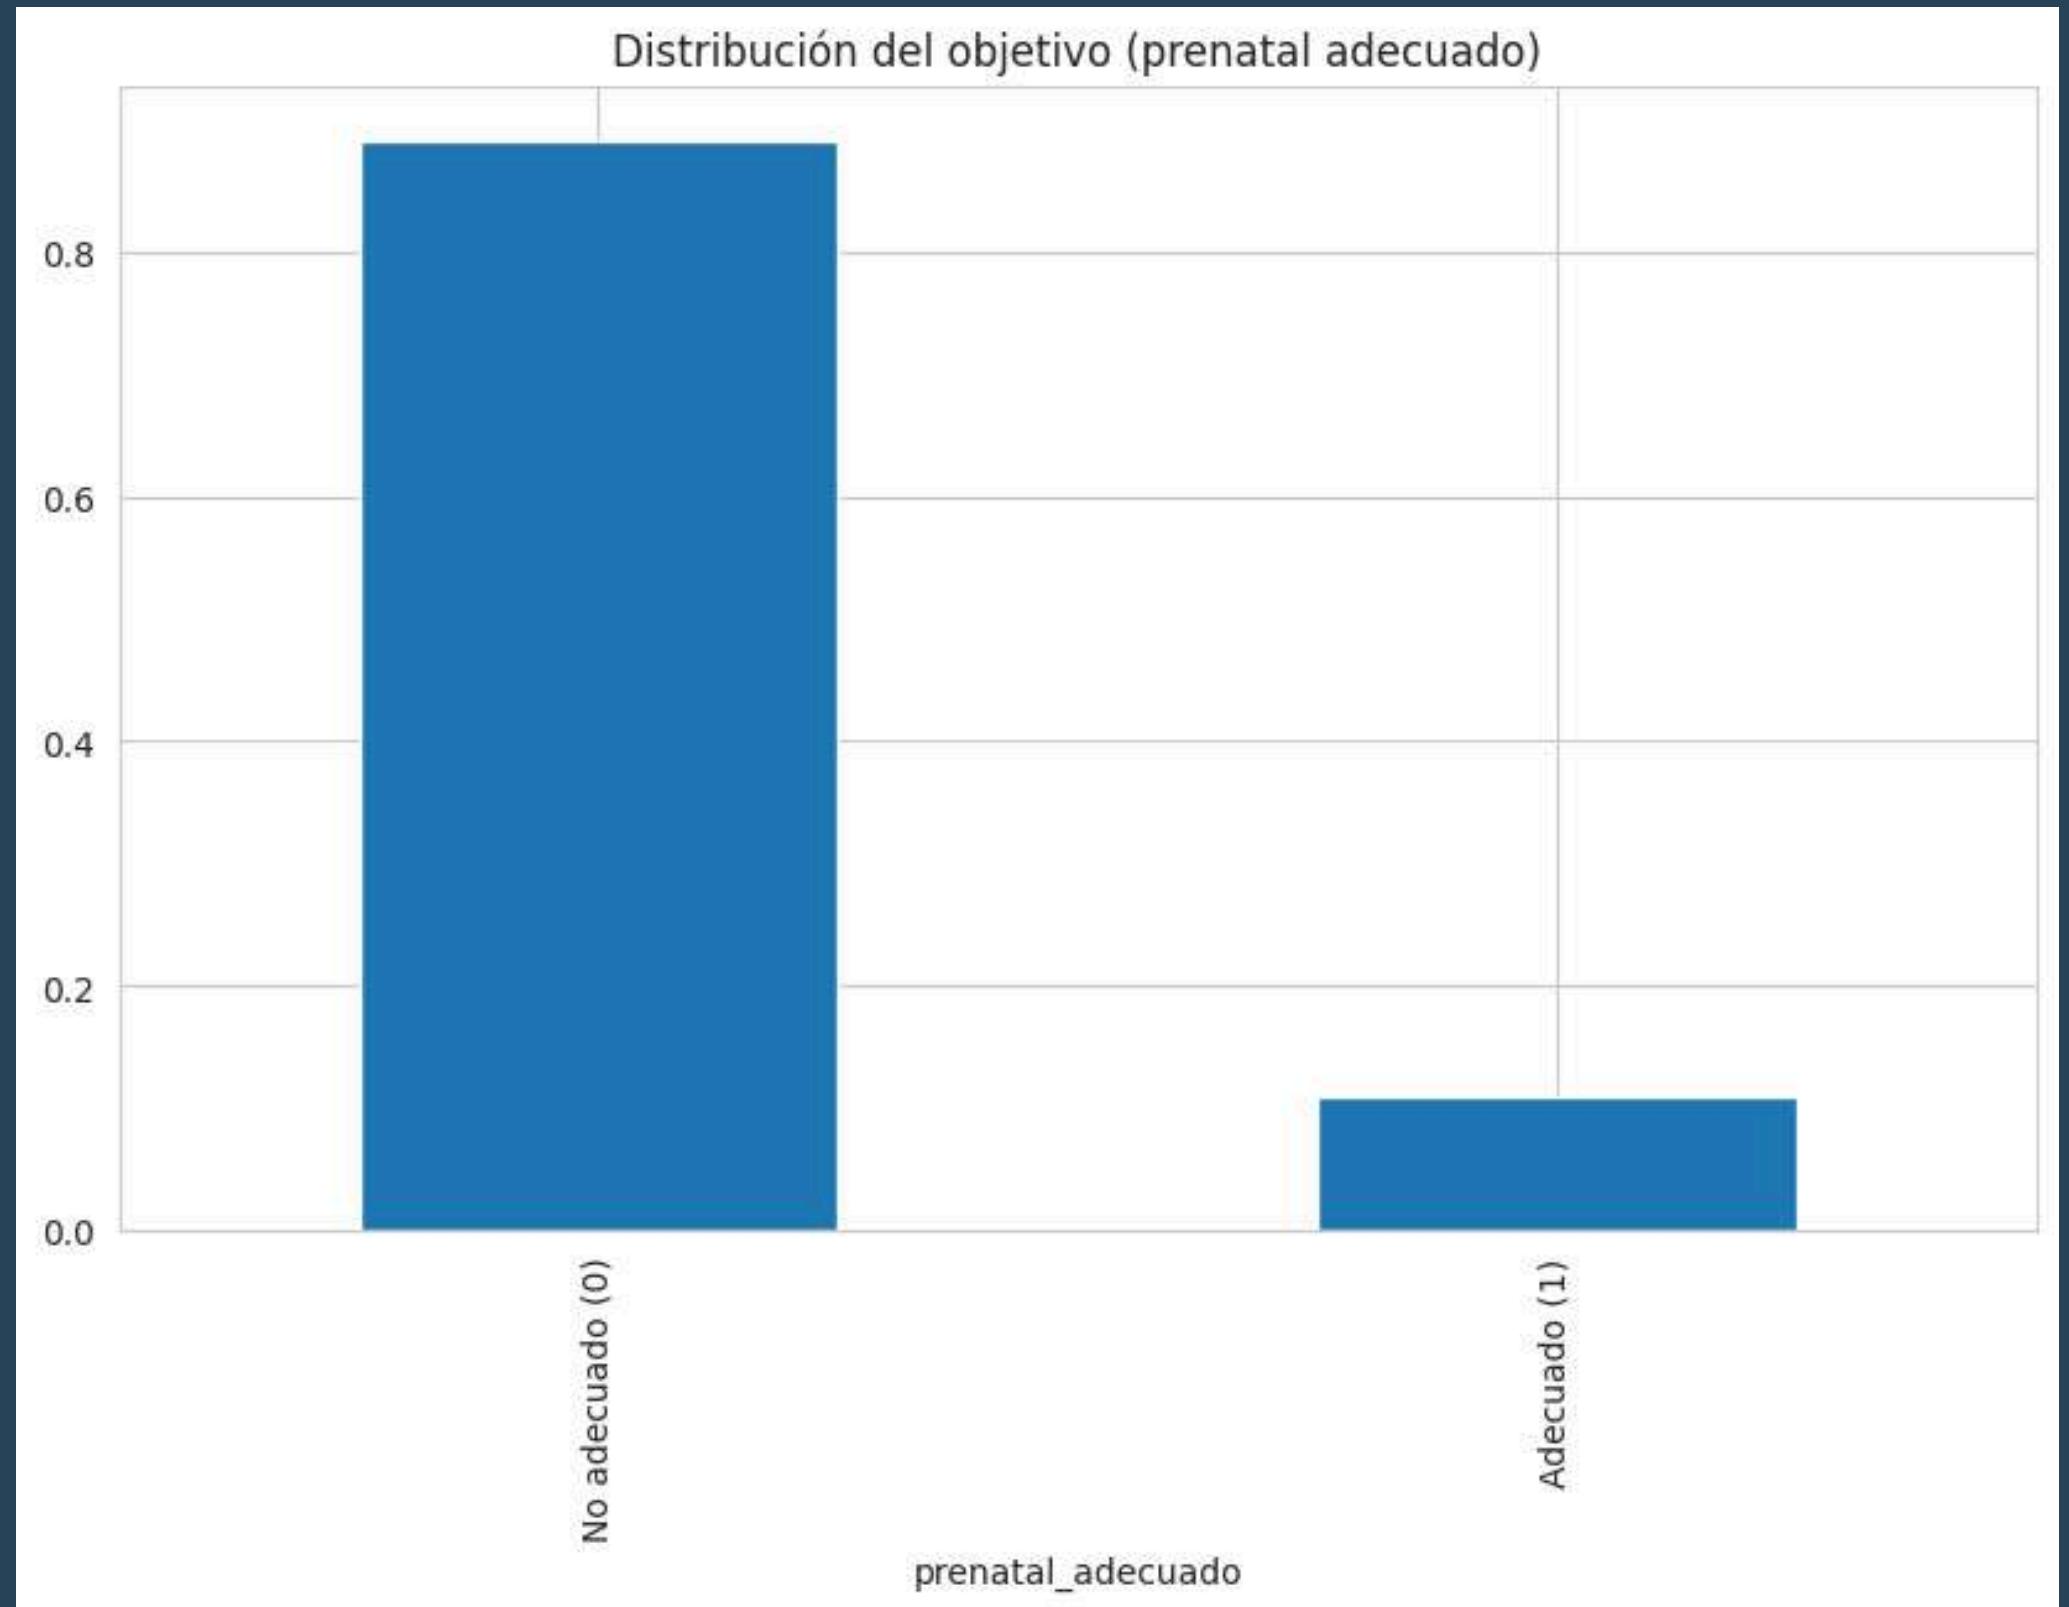


Figura 2: Distribución del objetivo

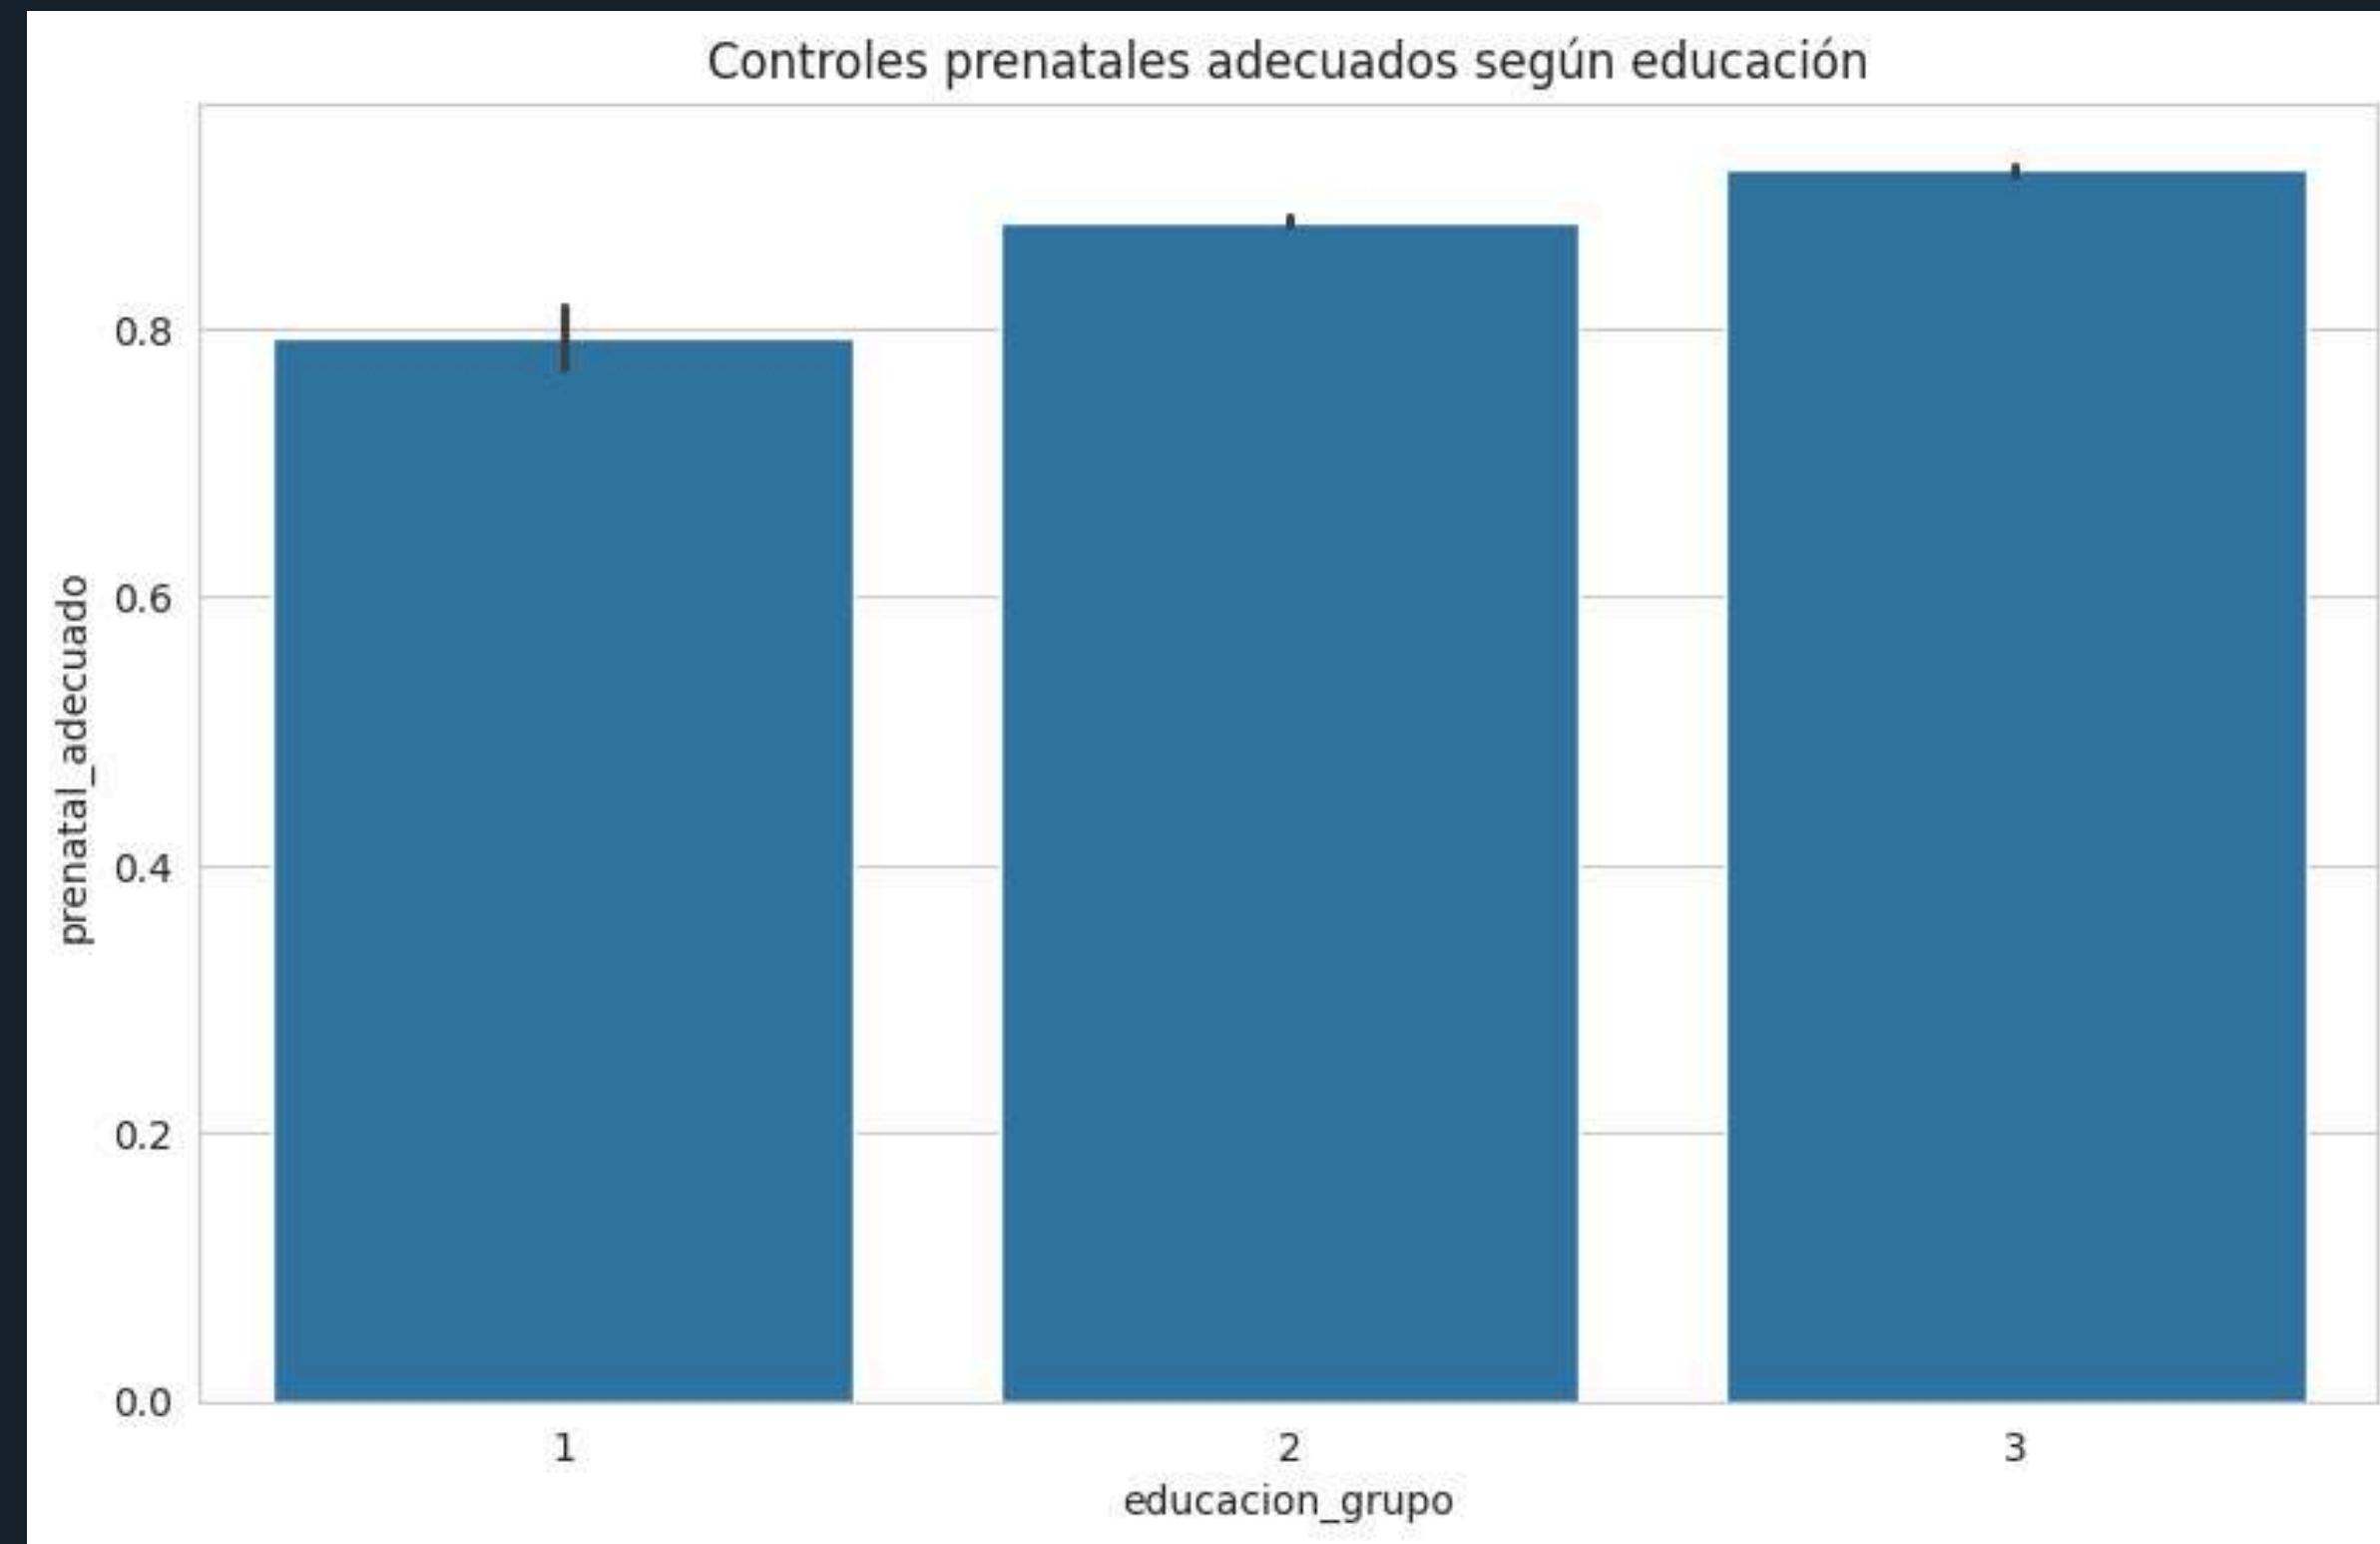


Figura 3: Controles prenatales adecuados según educación

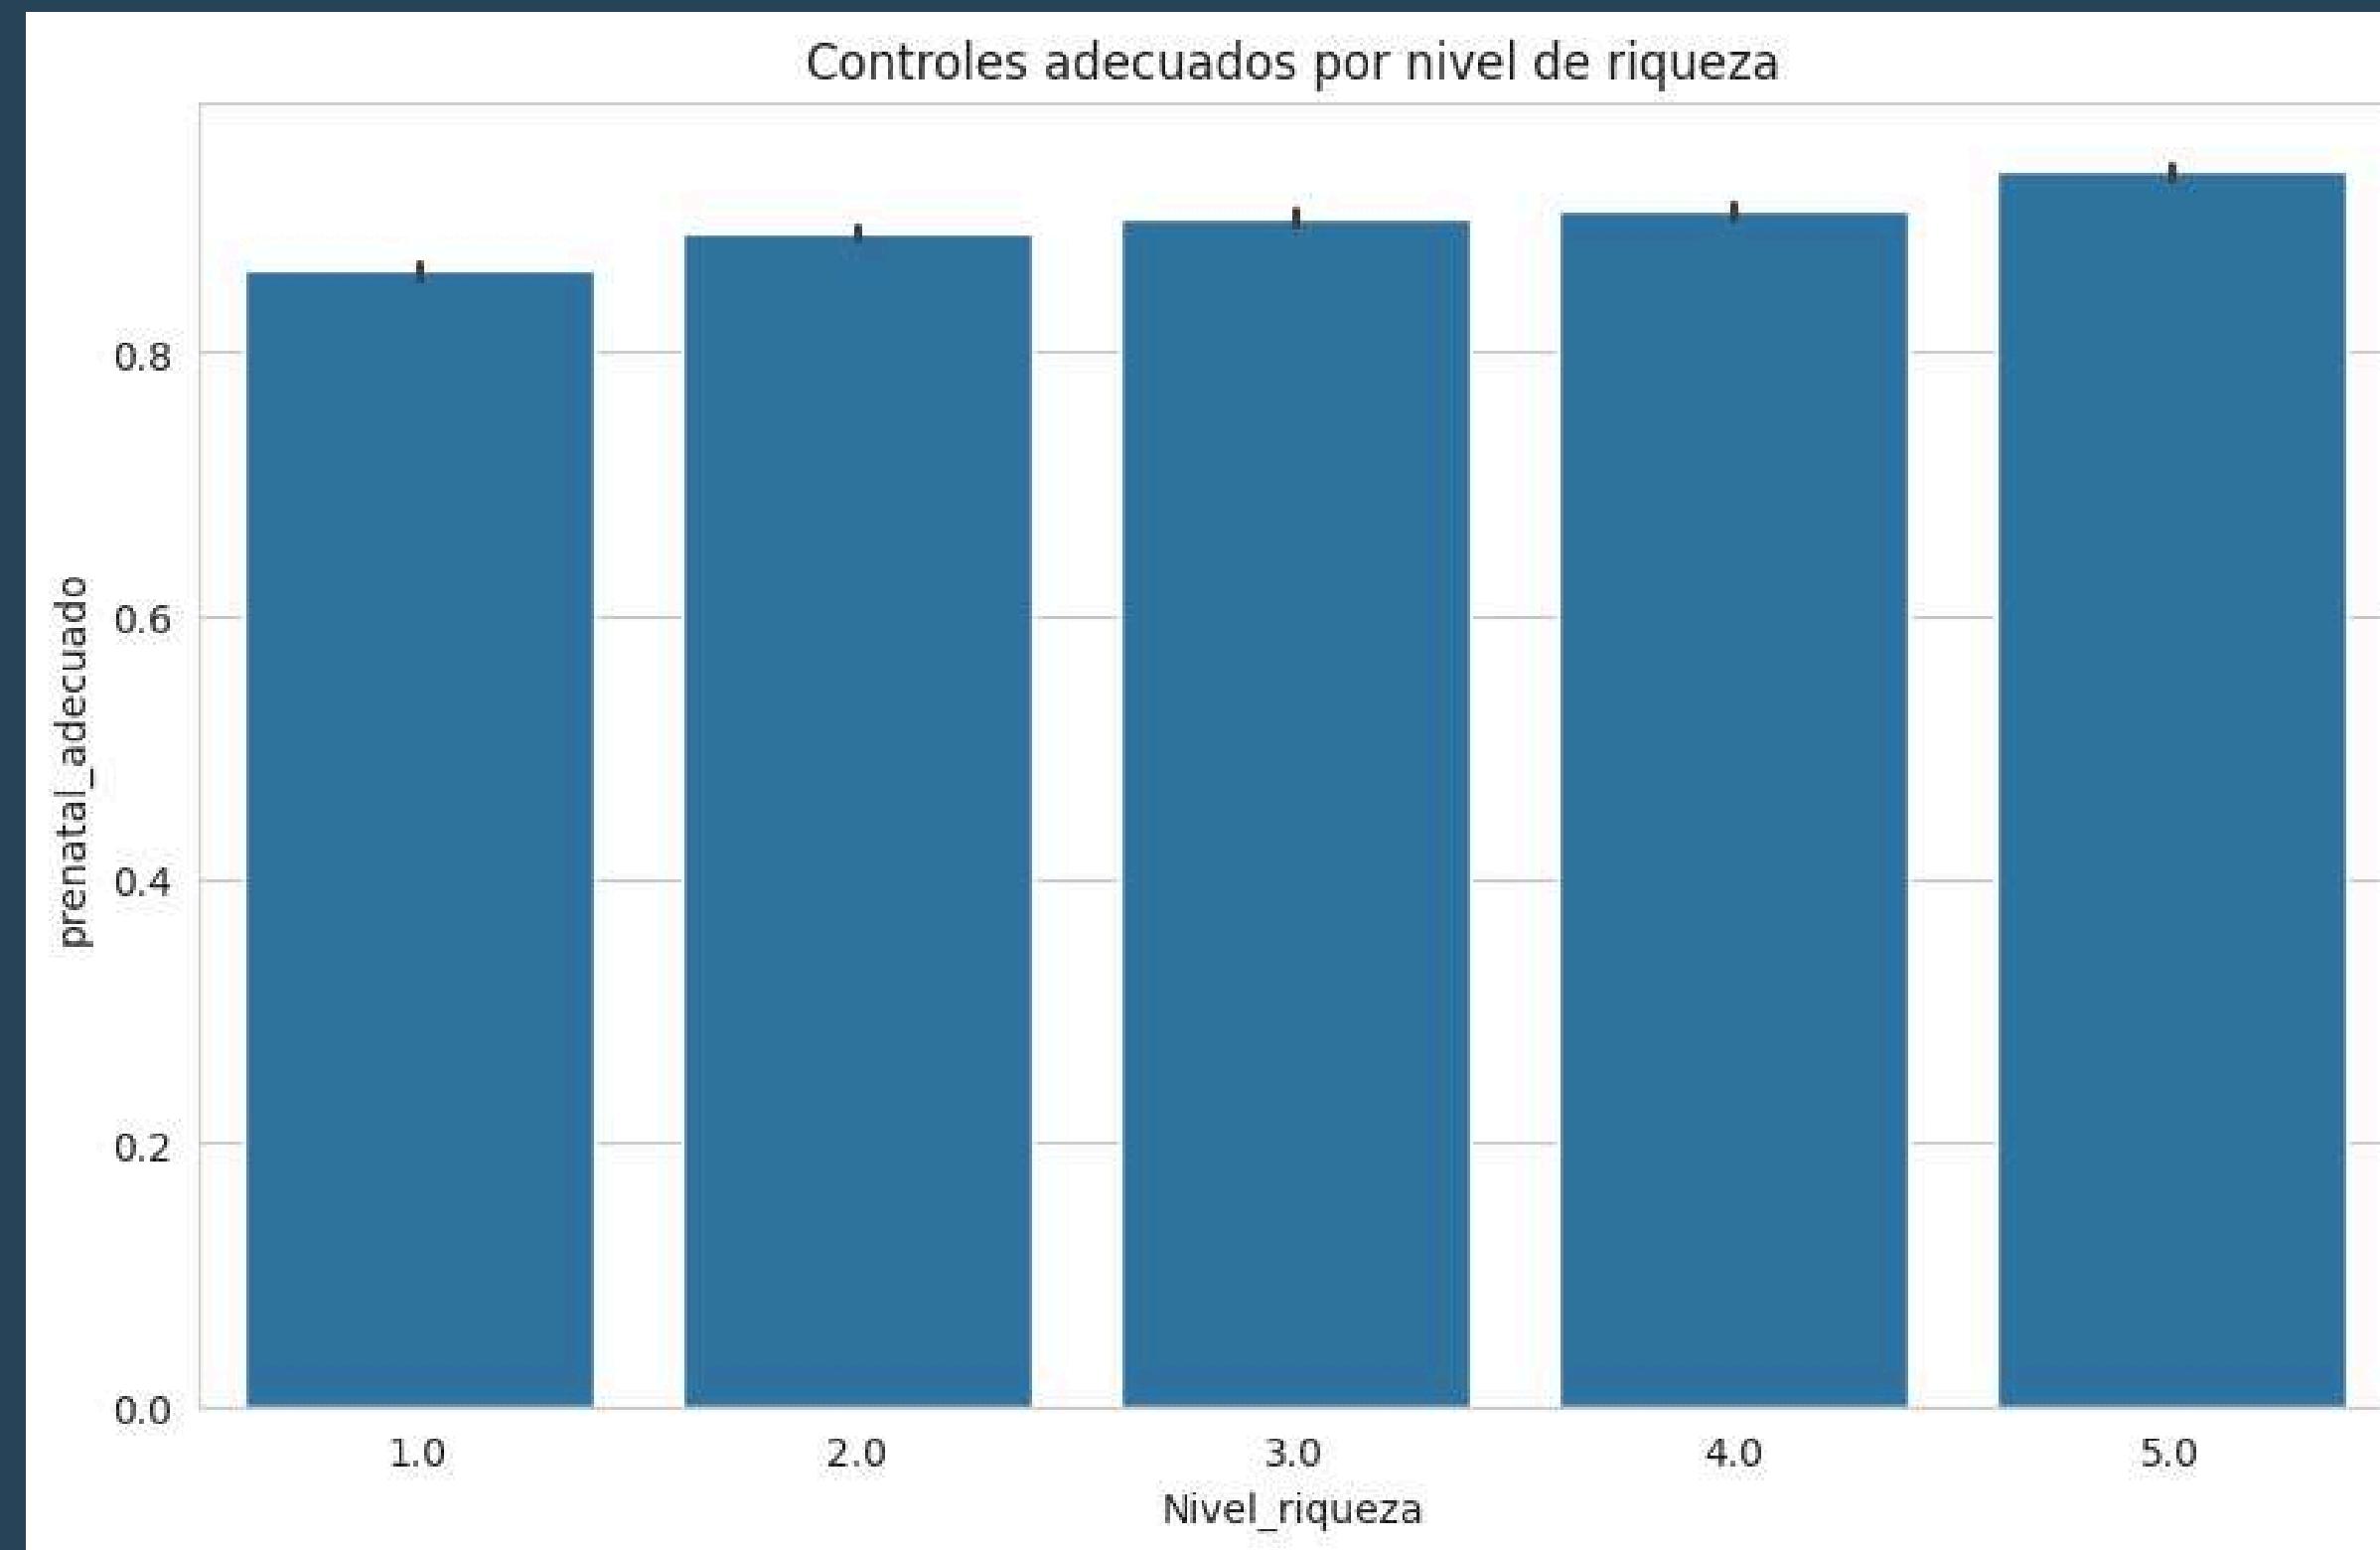


Figura 4: Controles adecuados por nivel de riqueza

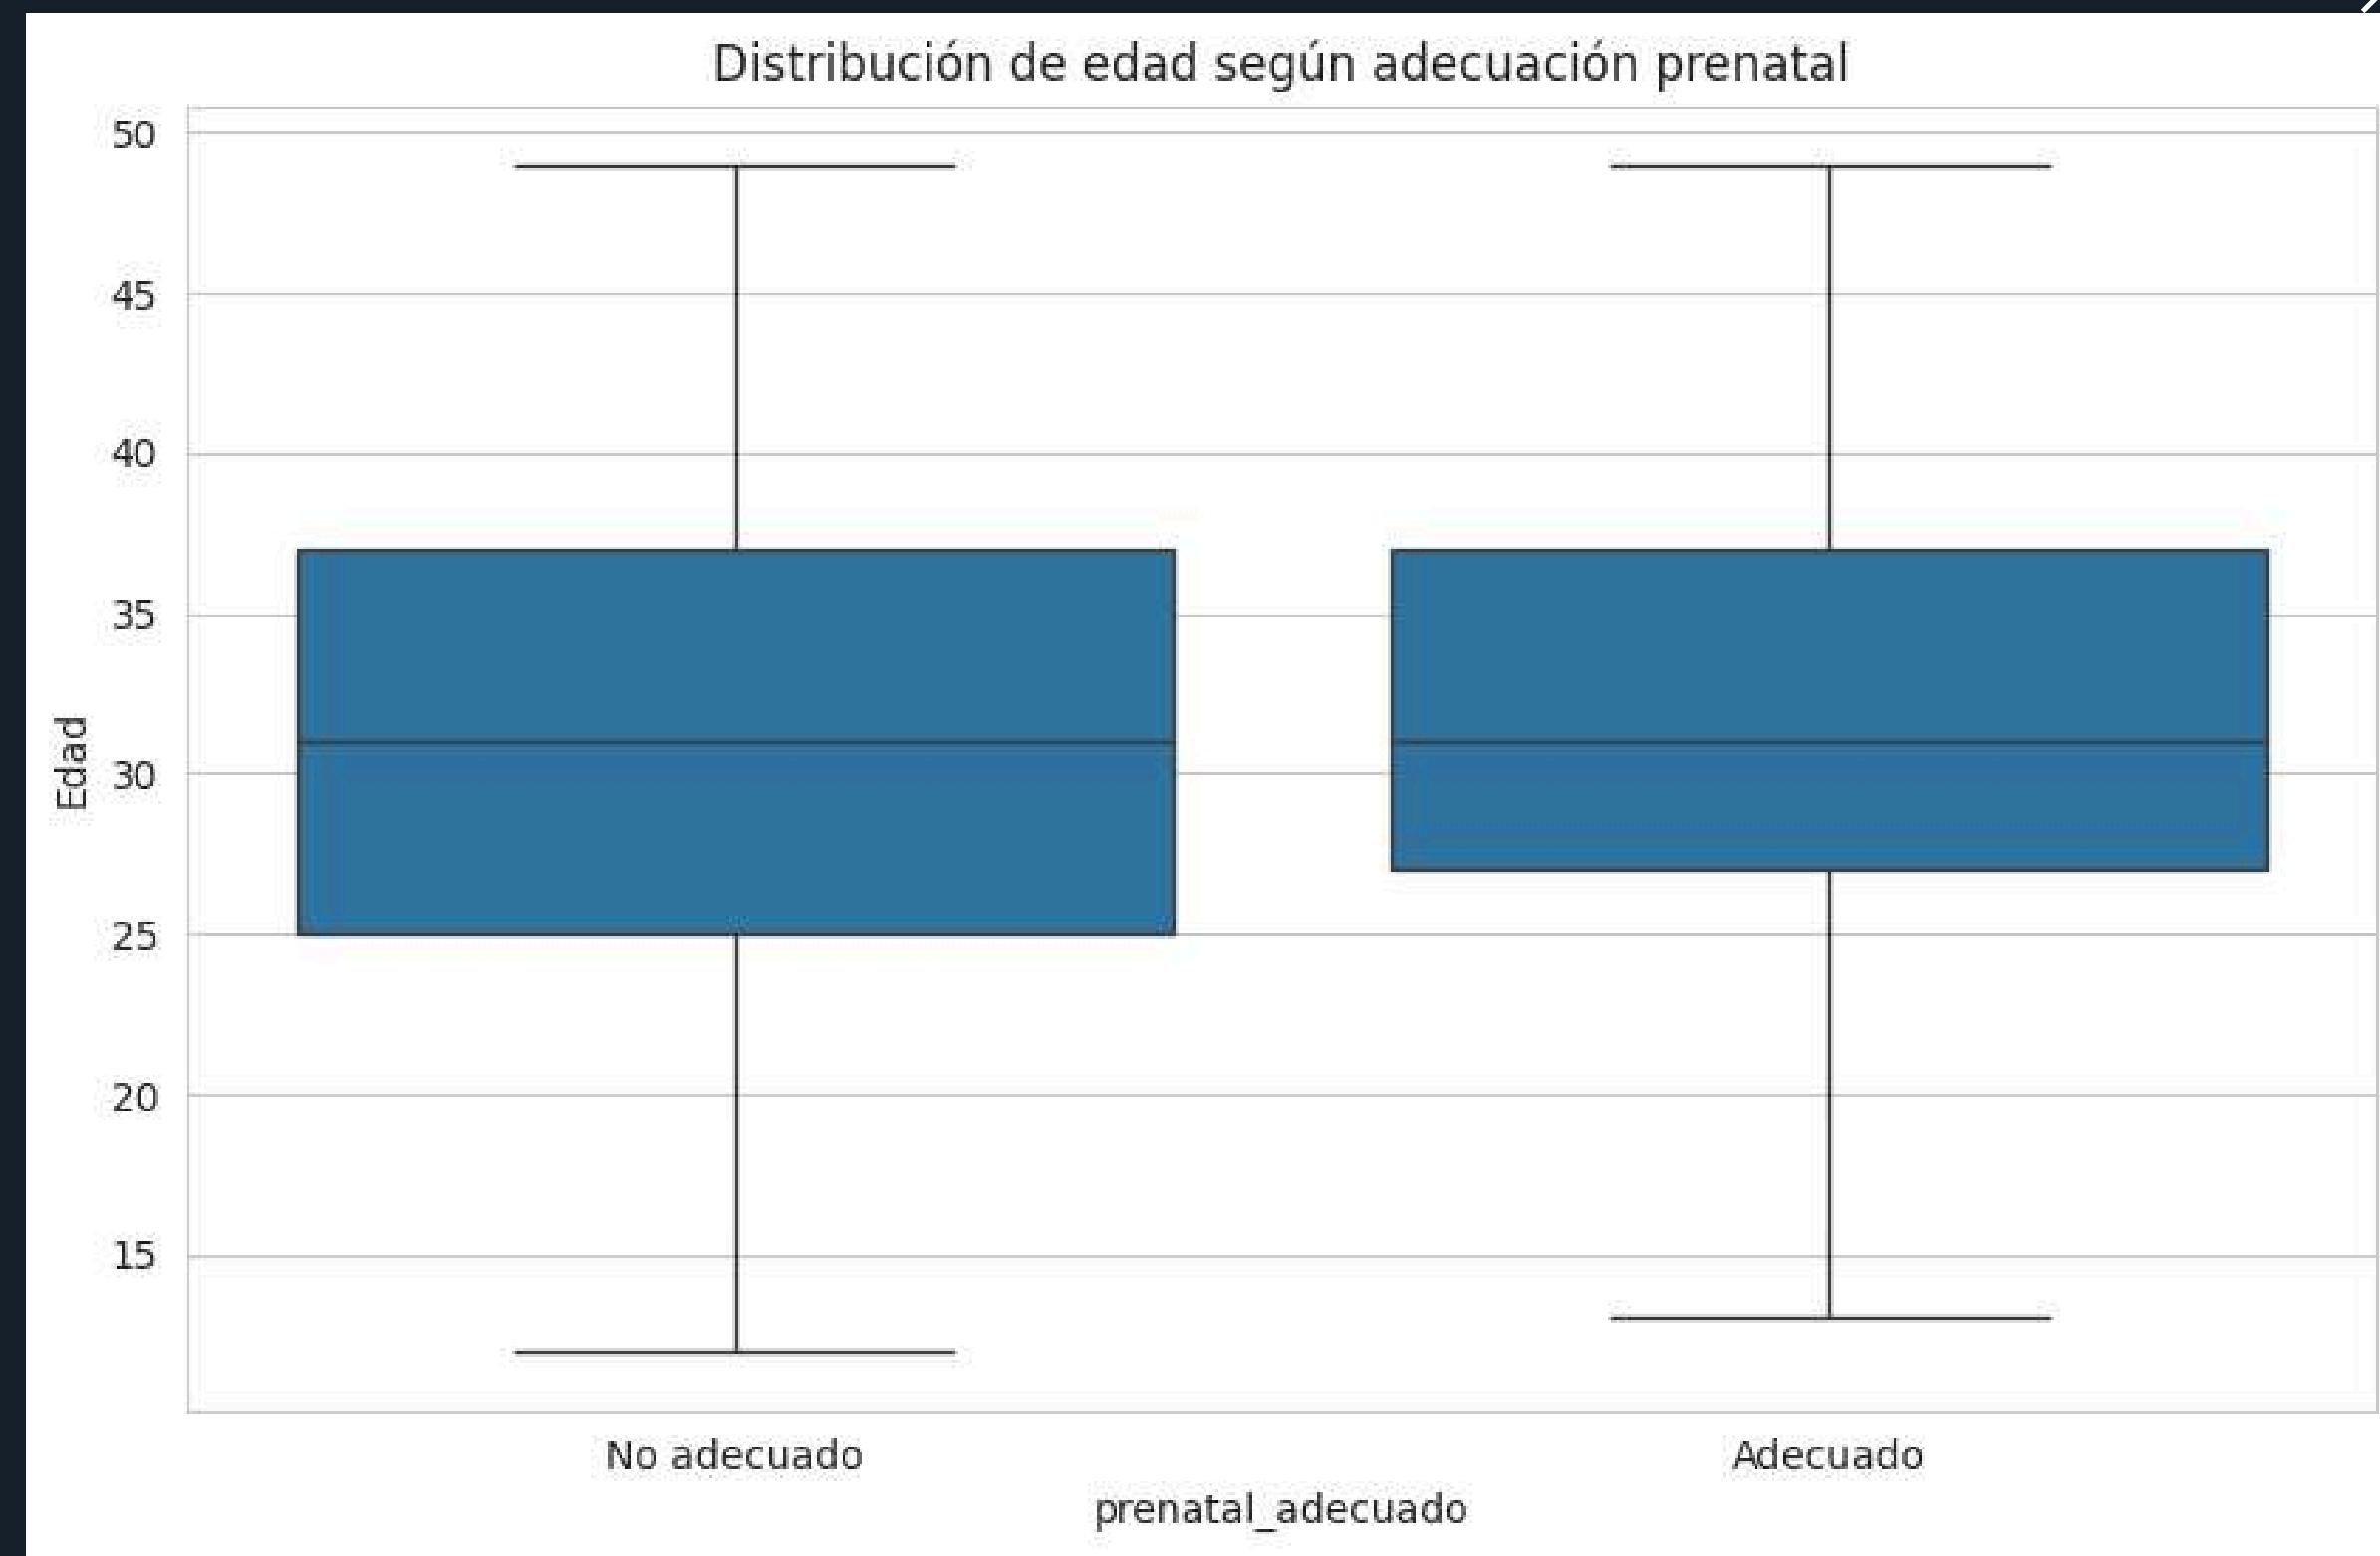


Figura 5: Distribución de edad según adecuación prenatal

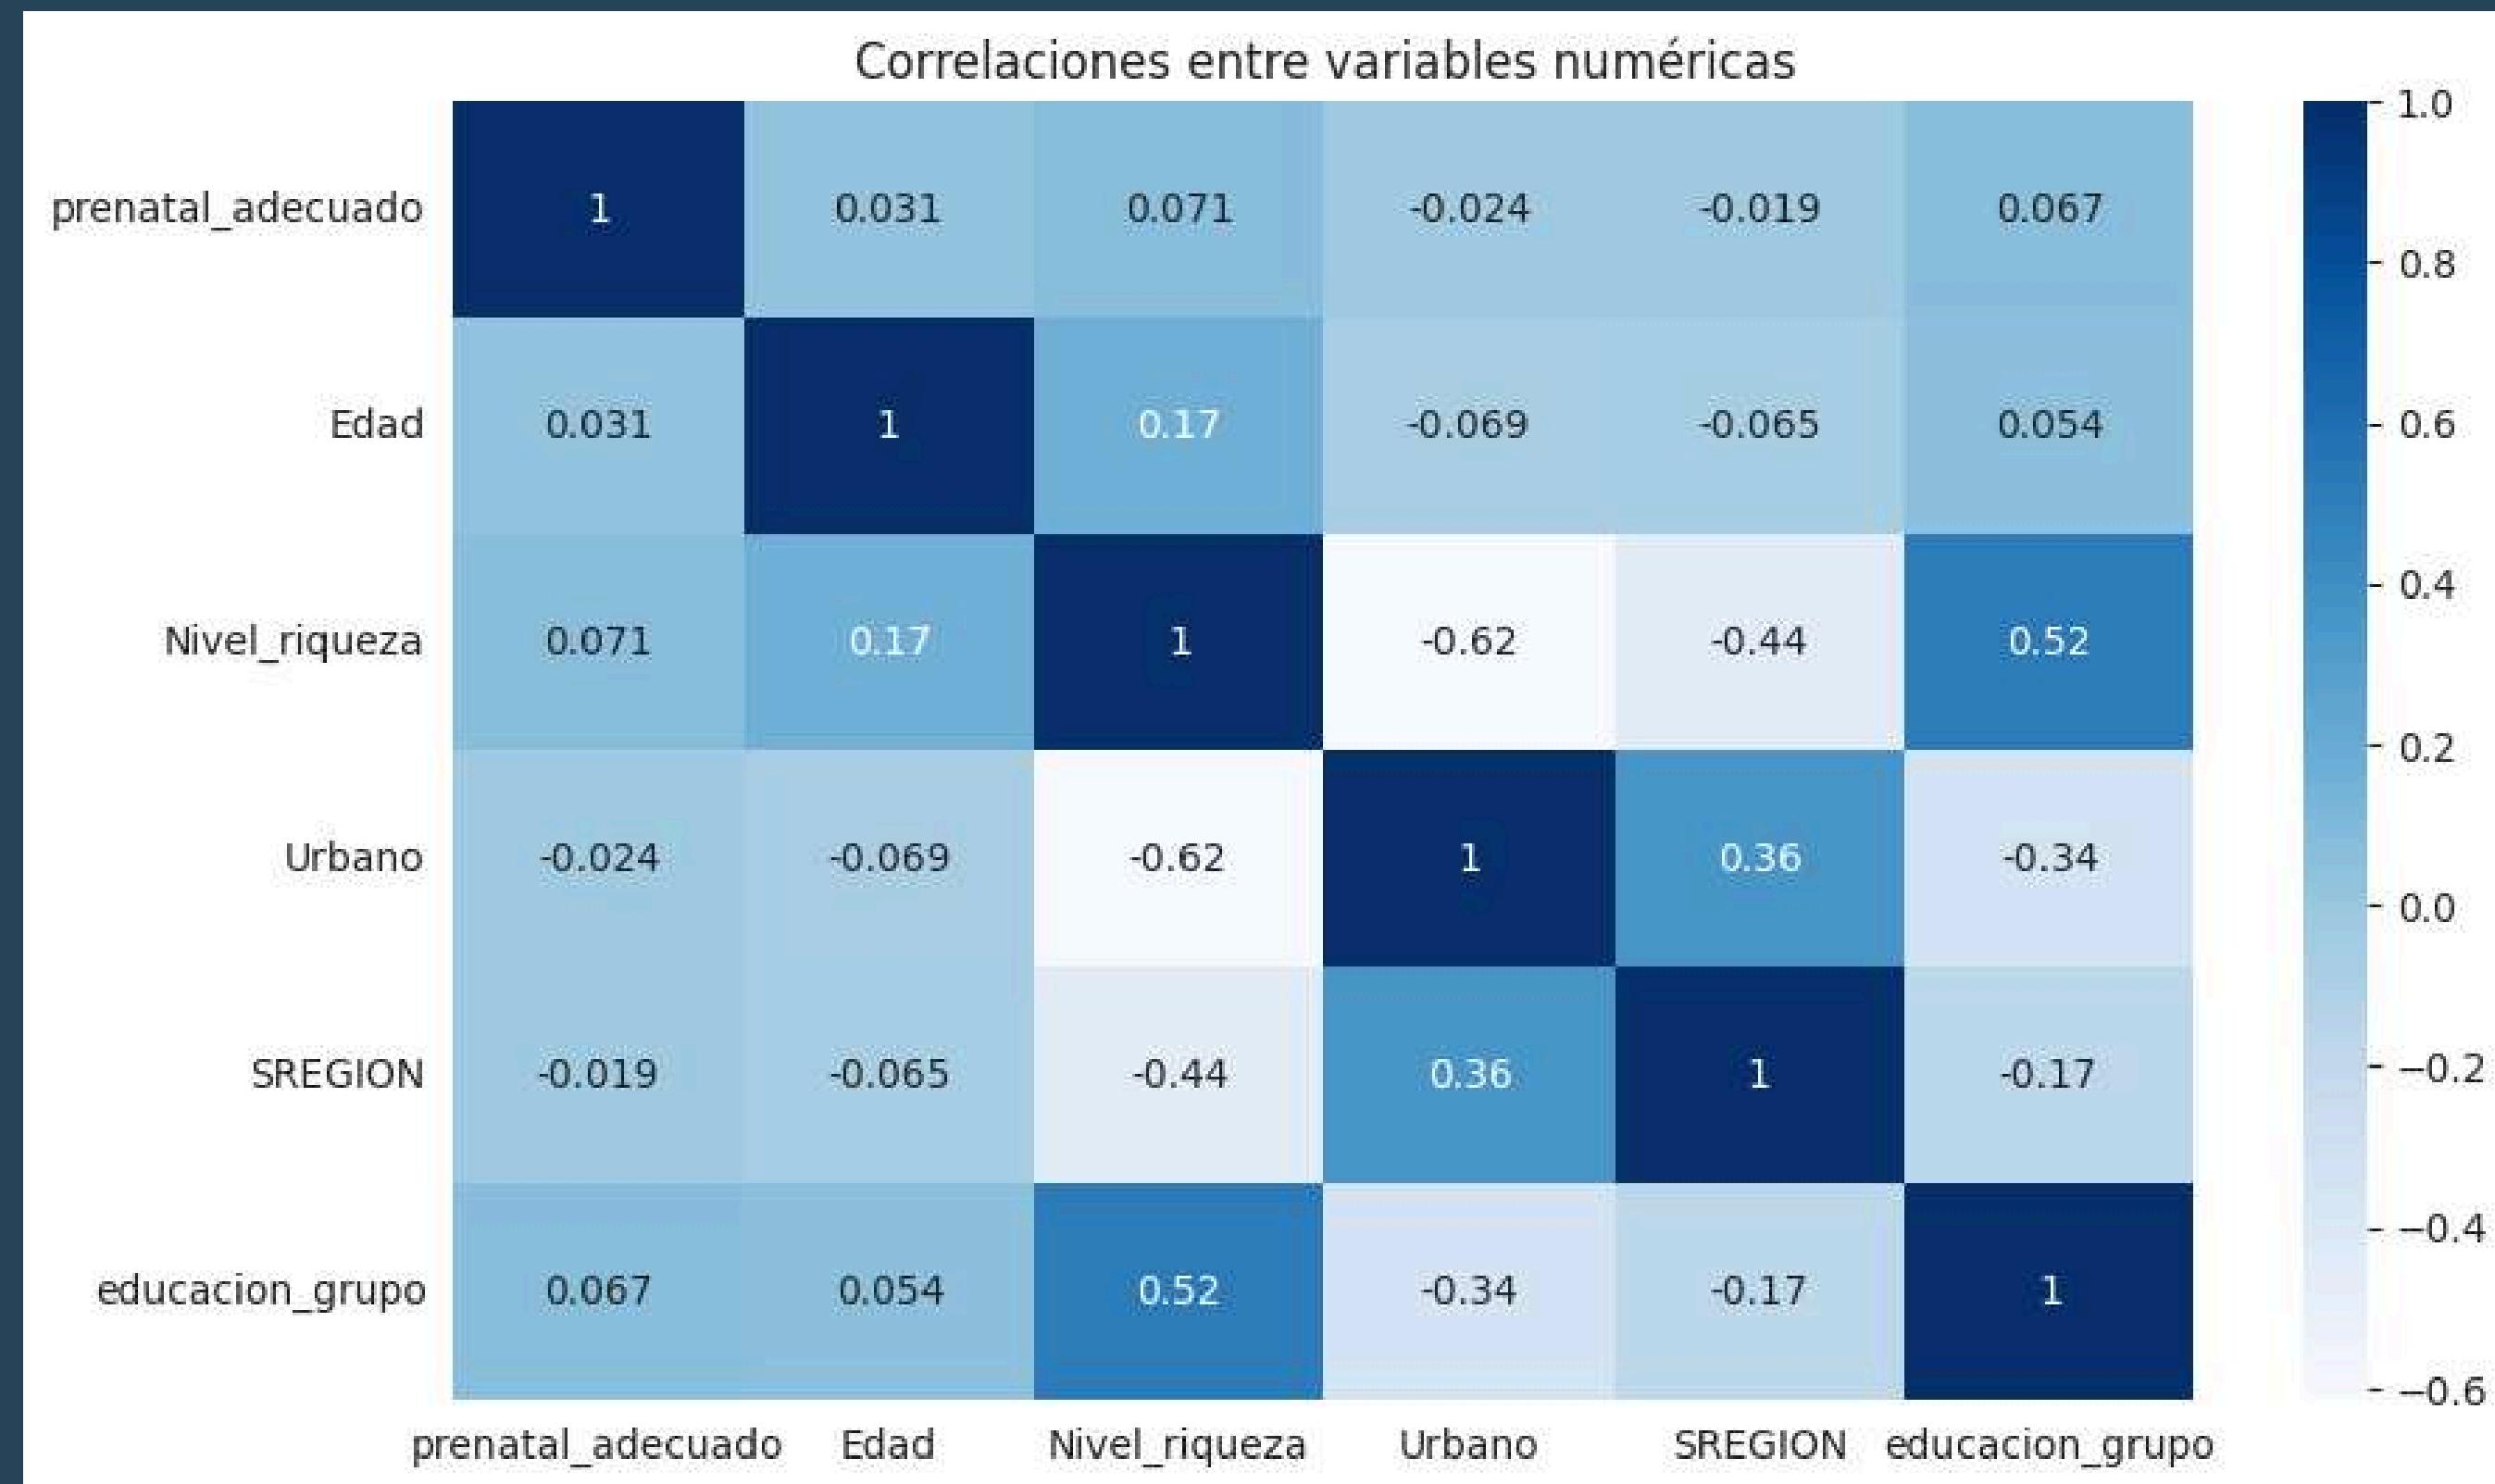
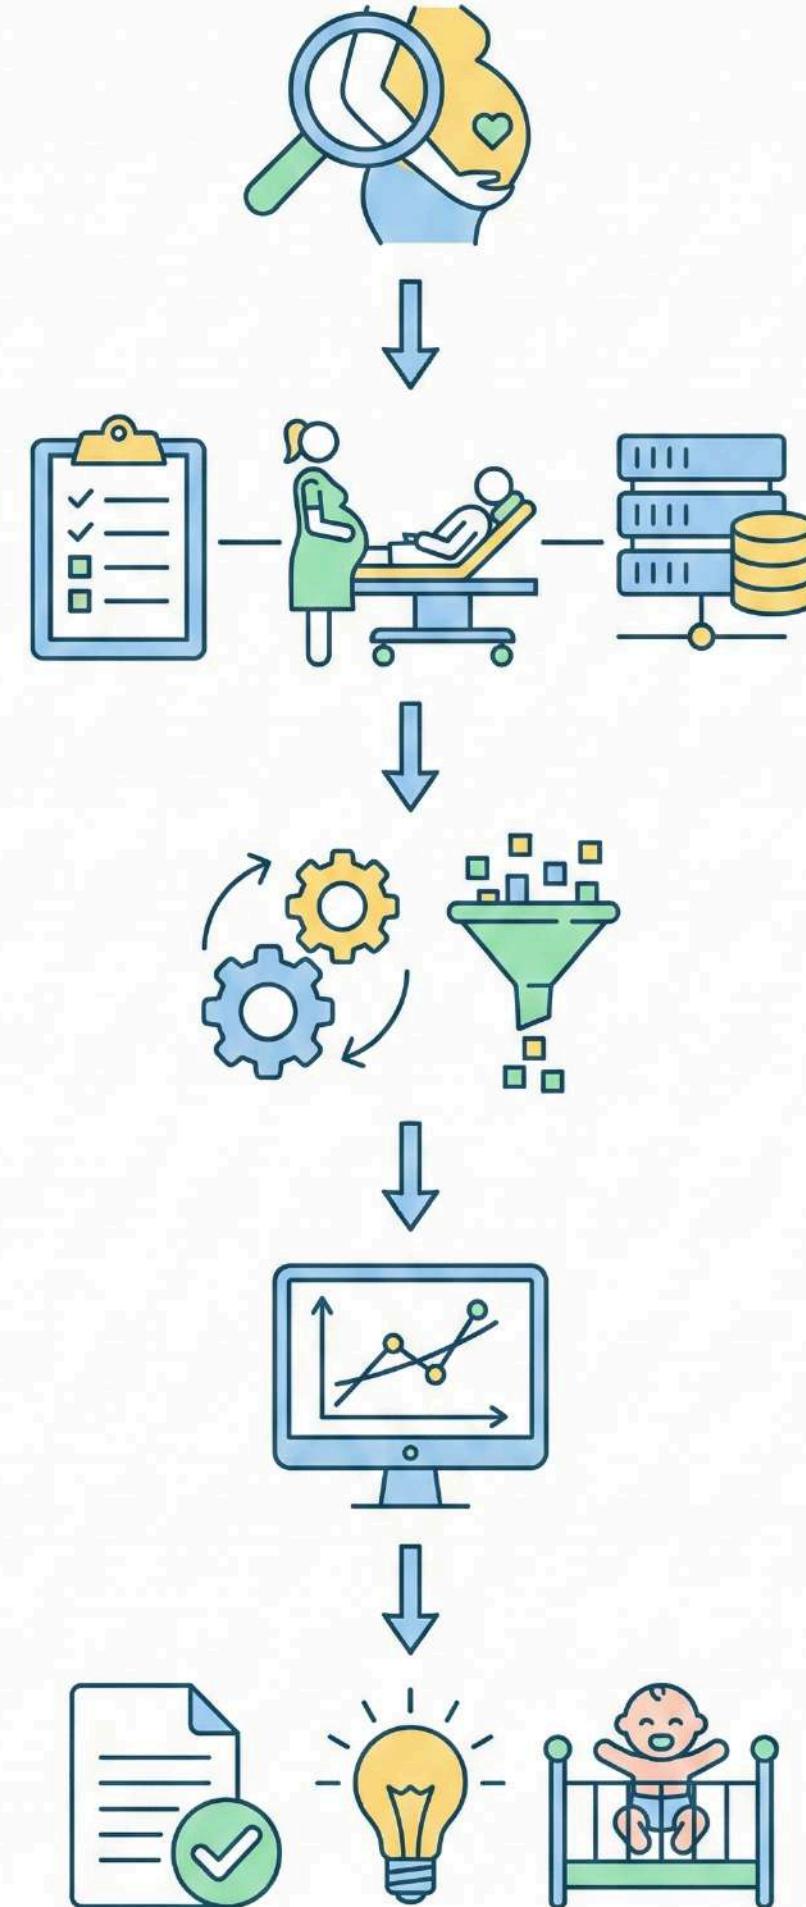


Figura 6: Tabla de correlaciones



Grupo 5

Estrategia Empírica (El Modelo)



TRABAJO 2:

Modelo Base (Baseline)

MODELO BASE: REGRESIÓN LOGÍSTICA



Ecuación:

$$Y_{it} = \beta_0 + \beta_1 Educ_i + \beta_2 Edad_i + \beta_3 Quintil_i + \beta_4 Reg_i + \beta_5 Urb_i + \epsilon_{it}$$

Variables:

- Educación
- Edad, Riqueza
- Región
- Zona Urbana

Se eligió Logit por ser el estándar para clasificación binaria (Asiste/No Asiste) y permitir interpretación de probabilidades.

RESULTADOS E INTERPRETACIÓN (ODDS RATIOS)

Hallazgos Clave:

- Educación: Odds Ratio > 1. A mayor educación, mayor probabilidad de asistencia.
- Riqueza: Odds Ratio 1.20. El dinero es un factor protector fuerte.
- Zona Urbana: Odds Ratio 0.79. Curiosamente, vivir en zona urbana redujo la probabilidad en este modelo (posible saturación de servicios).

Variable	Odds Ratio
Constante	2.3382
Educación_grupo	1.3215
Edad	1.0078
Nivel_riqueza	1.2092
SREGION	1.0342
Urbano	0.7936

EVALUACIÓN DE DESEMPEÑO Y LIMITACIONES

Validación Cruzada

Accuracy Promedio (CV): 0.8910 (+/- 0.0000)

F1-Score Promedio (CV): 0.9424 (+/- 0.0000)

Evaluación Final del Modelo de Clasificación:

Clase	Precisión	Recall	F1-score	Soporte
0	0.00	0.00	0.00	1879
1	0.89	1.00	0.94	15352
Accuracy			0.89	17231
Macro avg	0.45	0.50	0.47	17231
Weighted avg	0.79	0.89	0.84	17231

Hallazgos Clave:

- Accuracy del 89%. Parece un modelo excelente a primera vista.
- (El problema): La tabla de métricas por clase. Clase 0 (No asiste): Recall = 0.00, F1-Score = 0.00.

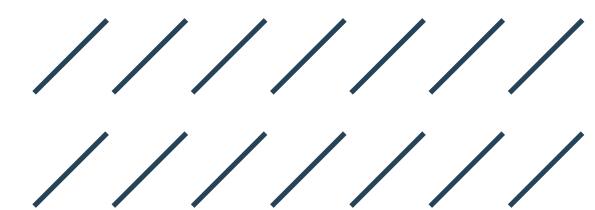
El 89% de exactitud es una ilusión. El modelo básicamente decidió 'apostar a lo seguro' diciendo que todas las madres cumplen con sus controles. El resultado es un algoritmo ciego: acierta en la mayoría, pero falla exactamente donde más lo necesitamos: en detectar a las madres que no van a asistir.

Necesitamos modelos que no solo acierten en promedio, sino que encuentren los casos difíciles.



Grupo 5

MODELOS MÁS COMPLEJOS Y OPTIMIZACIÓN



INGENIERÍA DE CARACTERÍSTICAS

Nuestro objetivo en este apartado es enriquecer la data para capturar no linealidad



INGENIERÍA DE CARACTERÍSTICAS



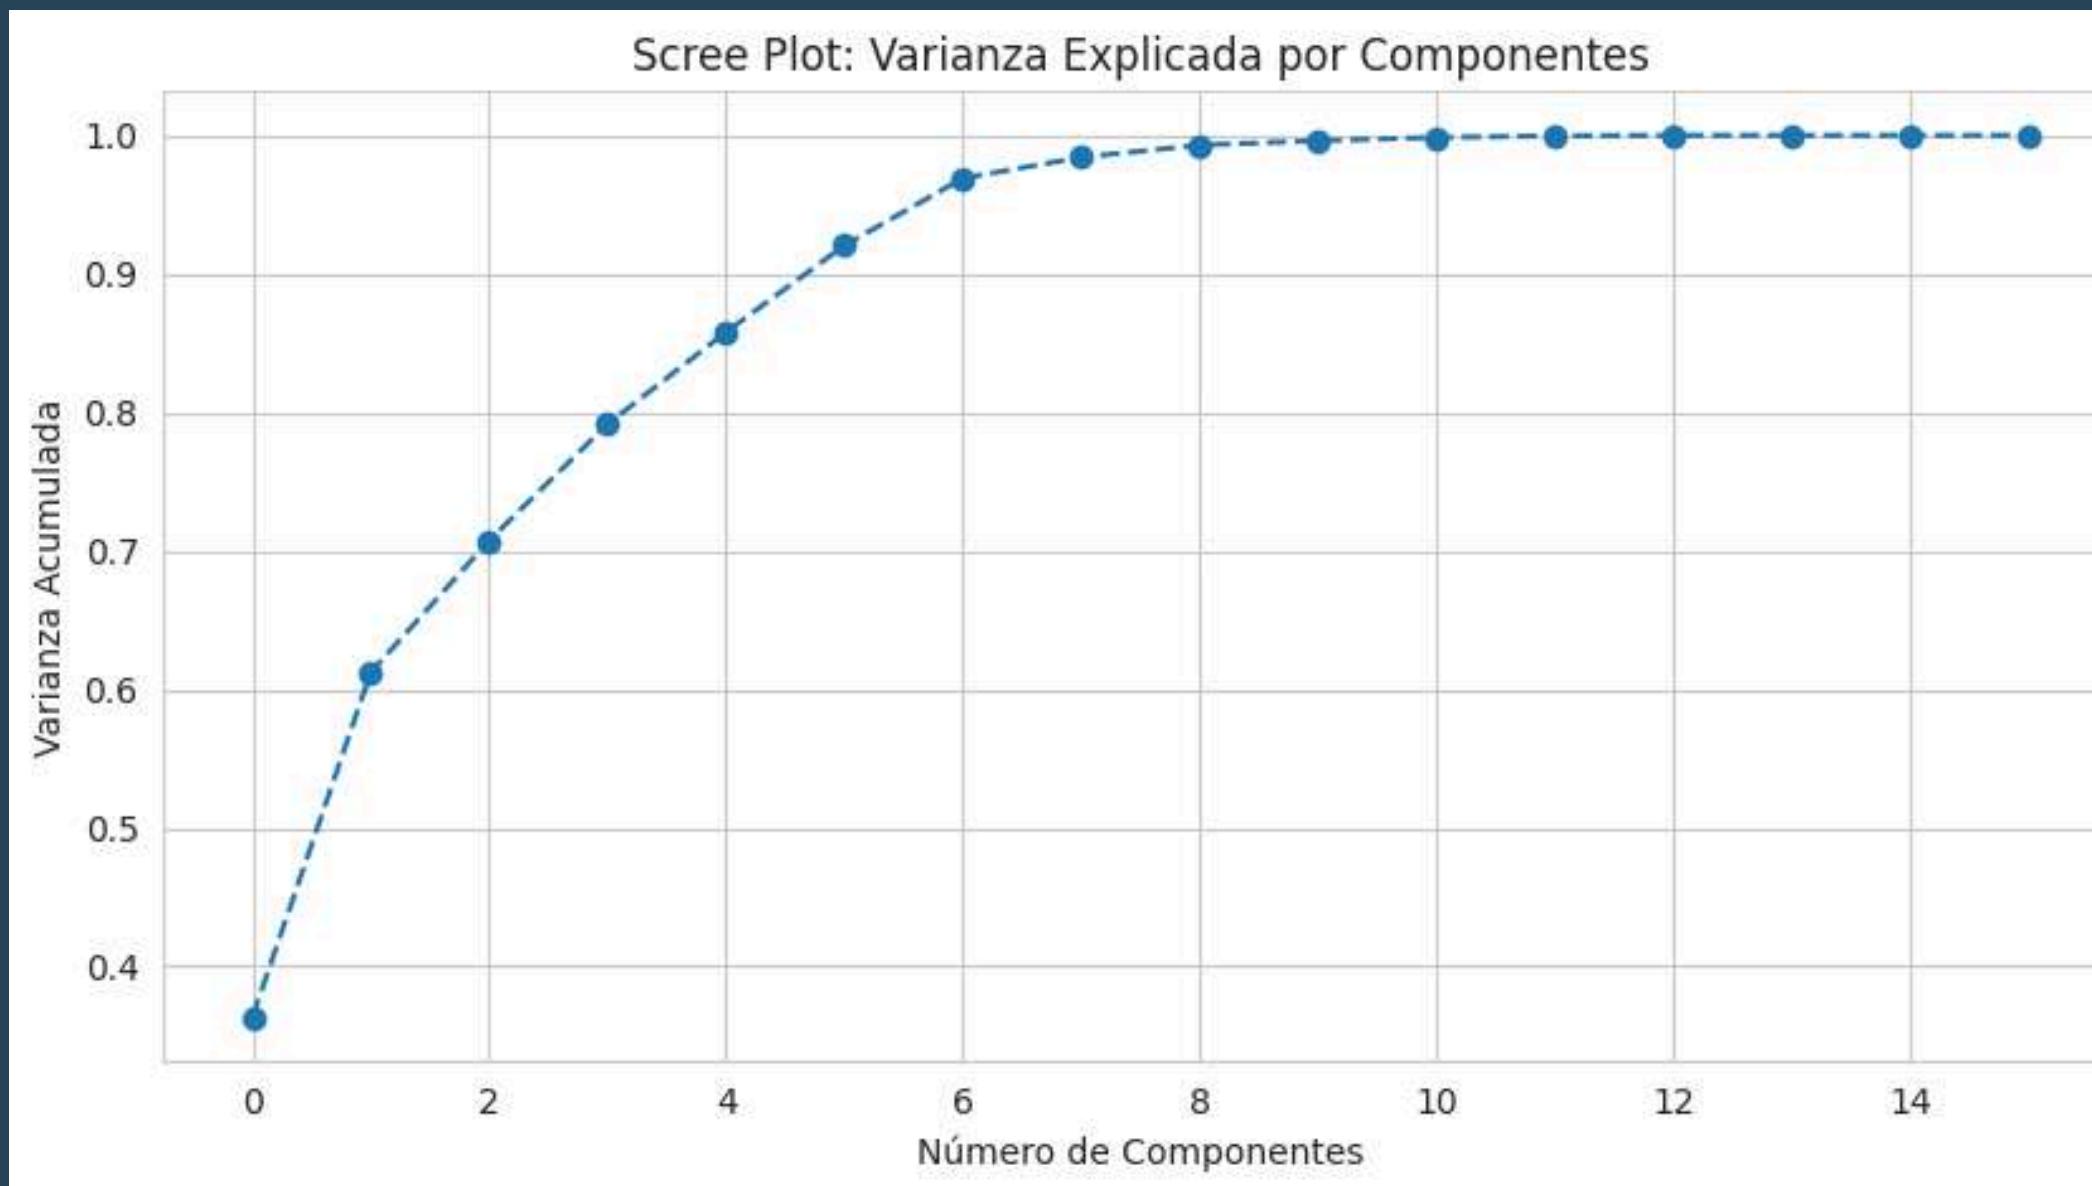
Nuestro objetivo en este apartado es enriquecer la data para capturar no linealidad:

- No Linealidad (Edad^2): Elevar la edad al cuadrado permite modelar relaciones curvas (ej. mayor riesgo en extremos de edad).
- Interacciones ($A \times B$): Variables combinadas que revelan cómo el efecto de la riqueza cambia según el nivel educativo.
- Flags de Riesgo: Indicadores binarios (0/1) explícitos para grupos vulnerables (adolescentes <18 o mayores >35).
- One-Hot Encoding: Convierte variables categóricas (como 'Región') en múltiples columnas binarias matemáticas.

Interacciones

- Edad condicionada por Riqueza
- Educación \times Riqueza
- Riqueza \times Urbano

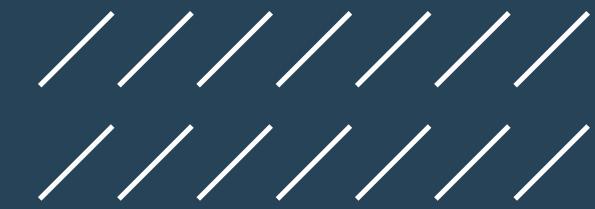
INGENIERÍA DE CARACTERÍSTICAS



Definición PCA: Técnica matemática que reduce la dimensionalidad de los datos buscando patrones de varianza.

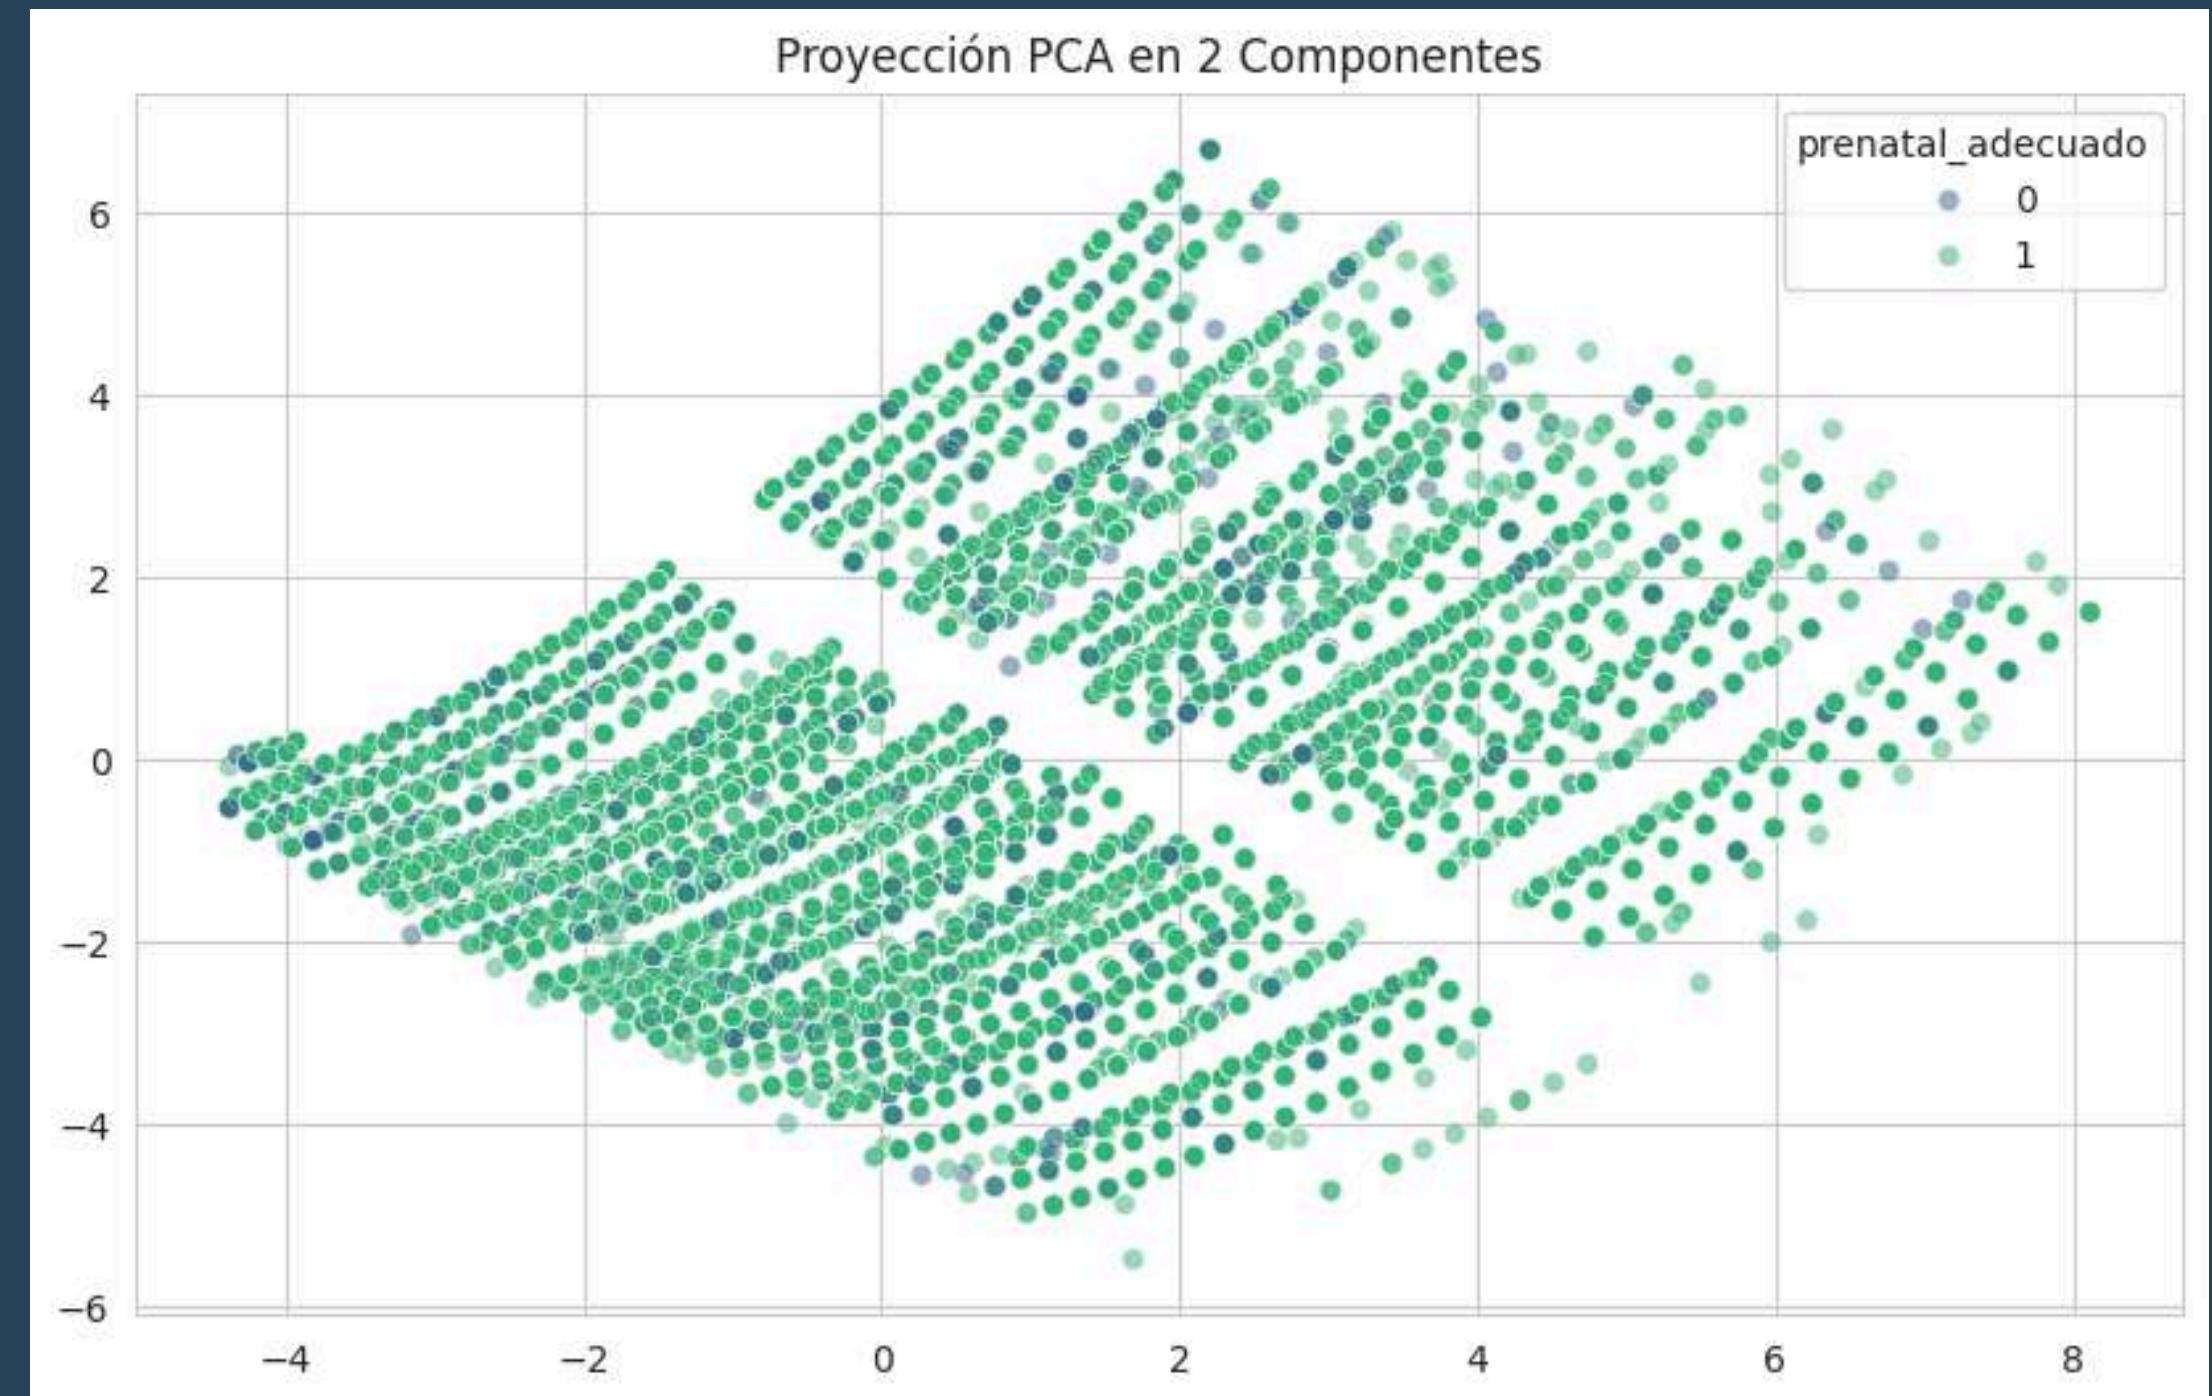
Hallazgo: La estructura es 'Combinatoria', lo que significa que no hay grupos separados limpiamente en el espacio.

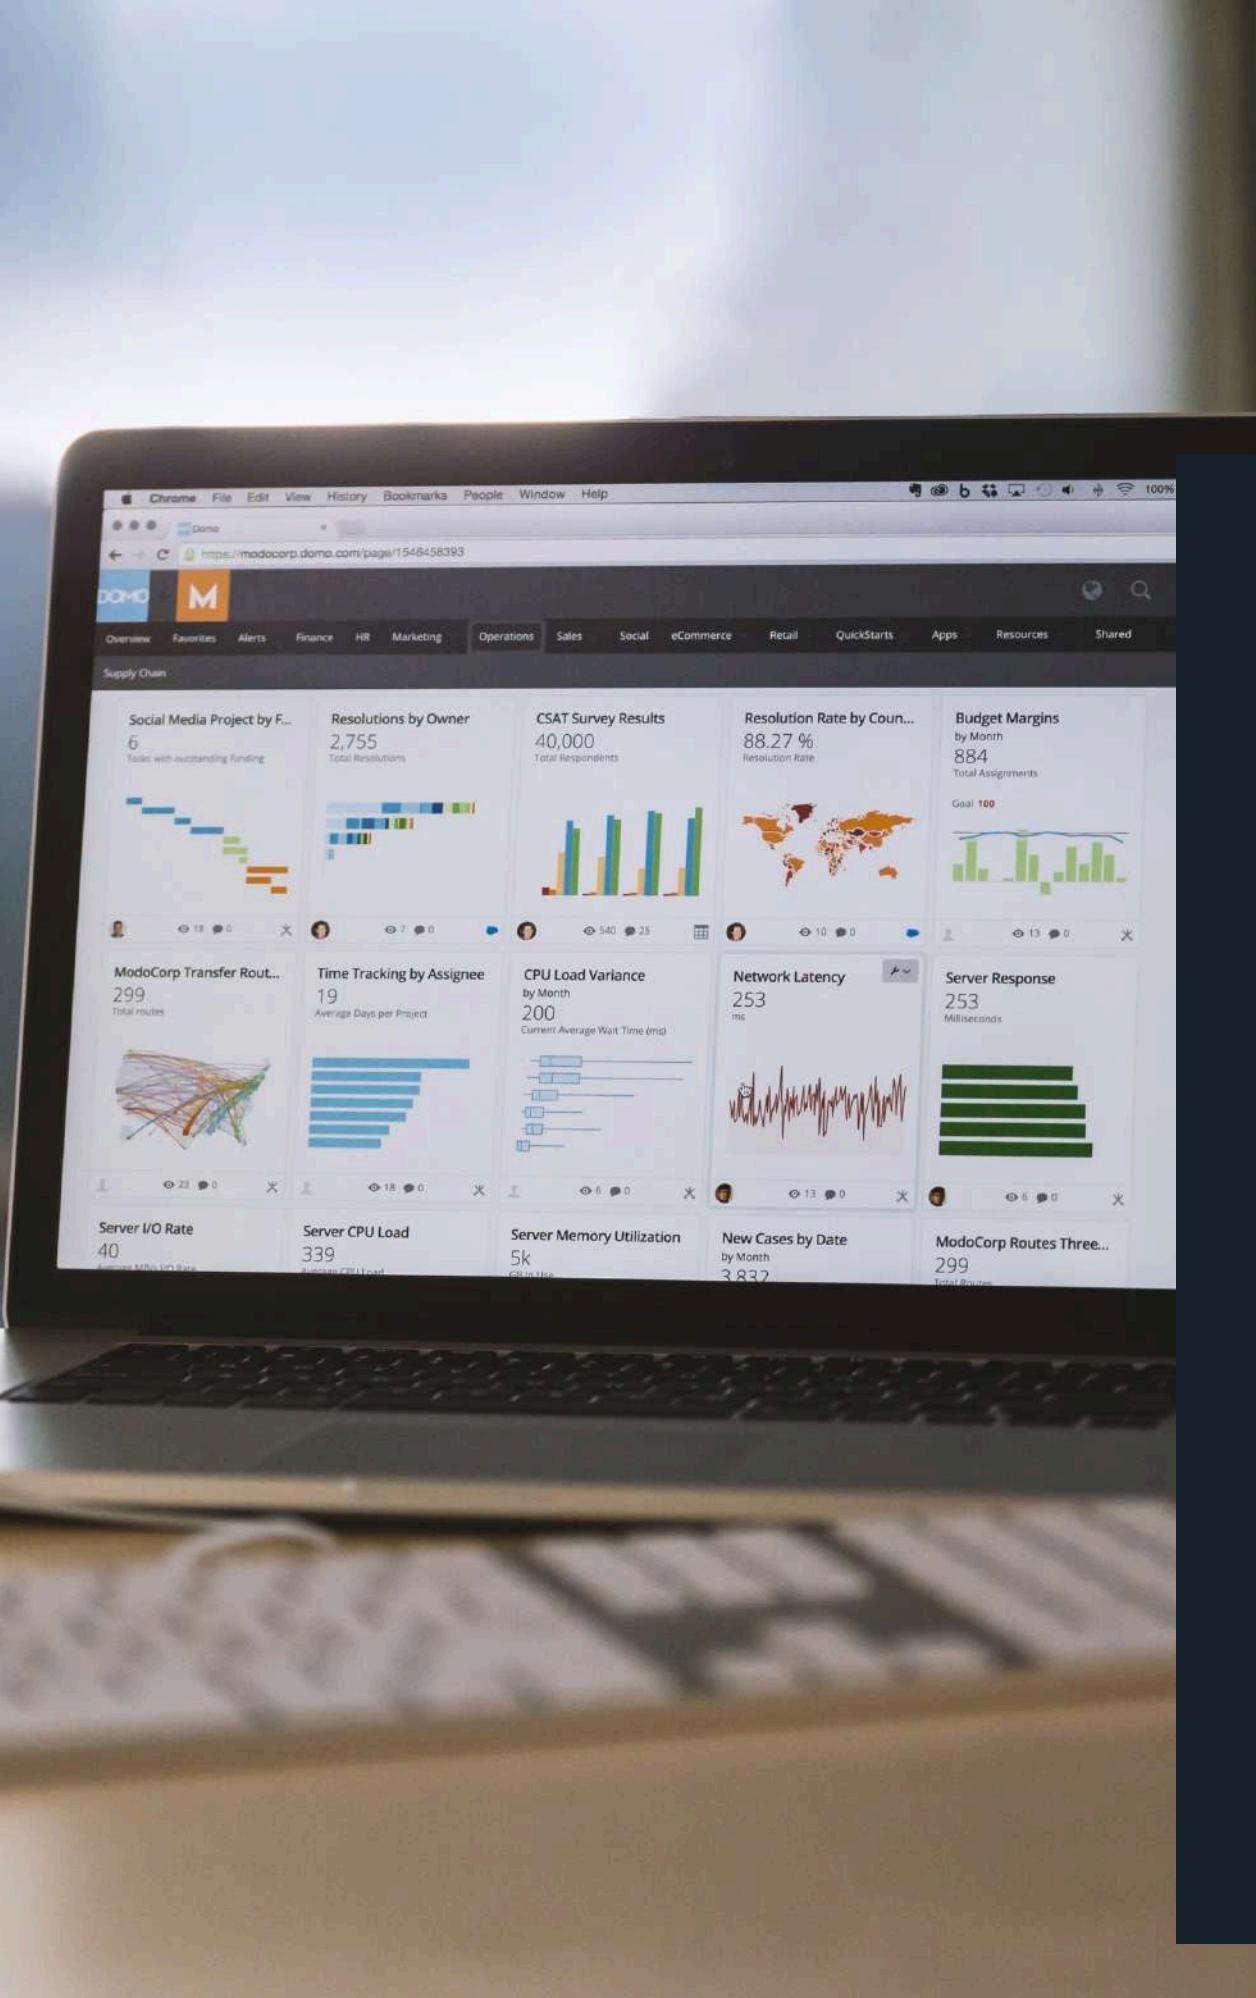
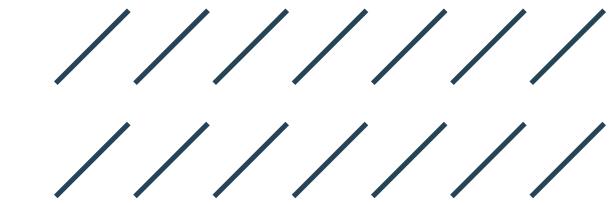
INGENIERÍA DE CARACTERÍSTICAS



Separabilidad Lineal: Capacidad de dibujar una línea recta para dividir clases. Aquí NO existe.

Conclusión: Se requieren modelos no lineales (flexibles) capaces de dibujar fronteras de decisión complejas.





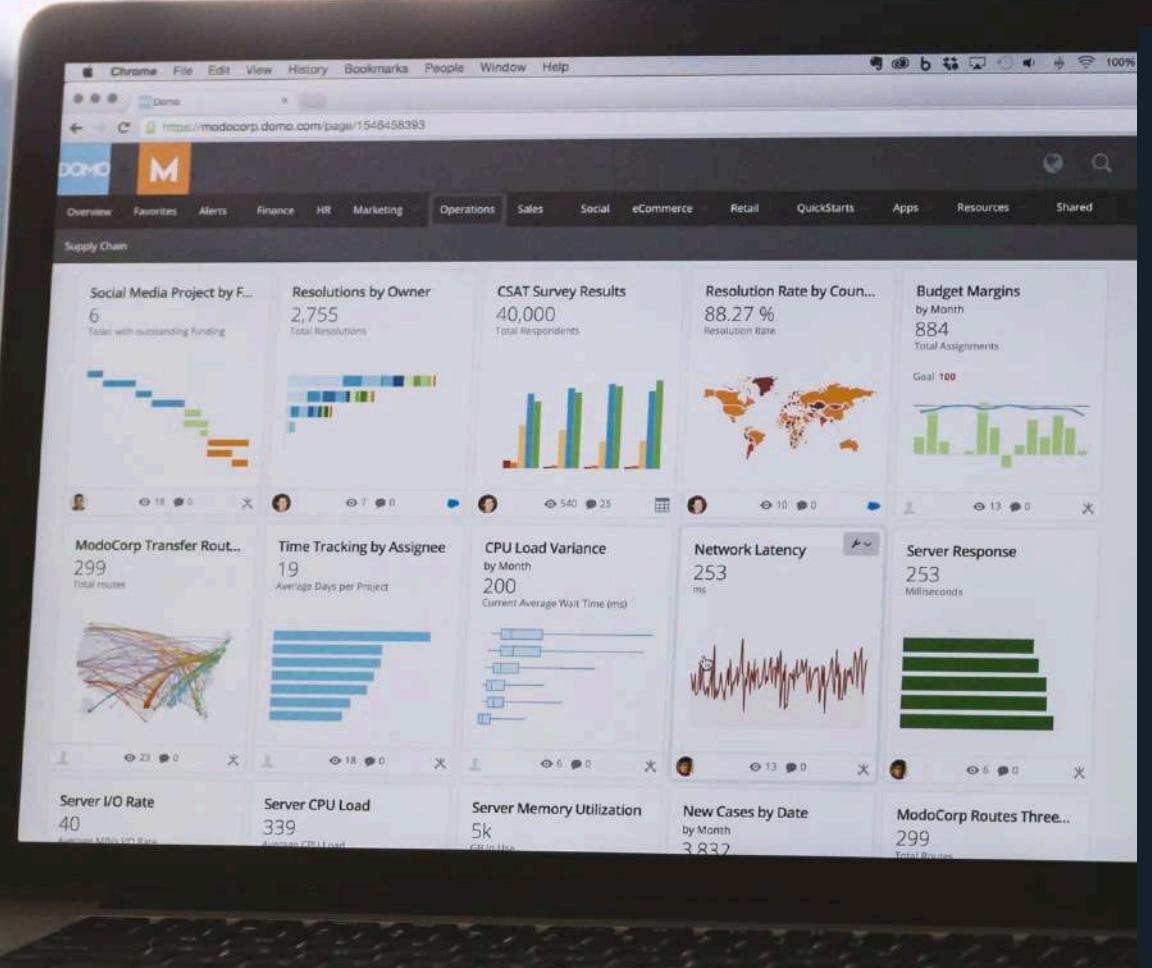
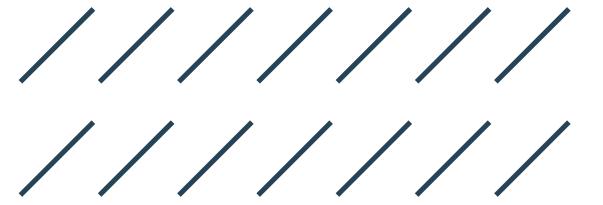
LOGIT MEJORADO

Pipeline: Secuencia automatizada de pasos (SMOTE → Escalado → Modelo) para evitar fugas de información.

Regularización L2 (Ridge): Penalización matemática a coeficientes grandes para reducir el sobreajuste (overfitting).

Métrica PR-AUC: Área bajo la curva de Precisión-Recall. Es el estándar de oro para datos desbalanceados.

Problema del Umbral 0.5: Usar el punto de corte estándar ignora que las clases no pesan lo mismo.



Falso Negativo (FN): El error más costoso. Una madre que necesitaba control pero el modelo predijo que NO.

Fallo Inicial (Umbral 0.5): Con el umbral por defecto, el Recall (Sensibilidad) era solo 0.619, dejando sin detectar al ~38% de los casos de riesgo.

Falso Positivo (FP): Error menor. Una madre alertada innecesariamente (gasto de recursos, pero salva vidas).

Costo Asimétrico: Definimos que 1 FN cuesta más del doble que 1 FP (0.7 vs 0.3).

Umbral Óptimo (~0.01): Bajamos la vara de decisión drásticamente para capturar todos los casos de riesgo (Recall=1.0).



Table 1: Comparación de Métricas del Modelo Logit Mejorado por Umbral

Métrica	Umbral = 0.5	Umbral Óptimo
PR-AUC	0.9205	0.9205
ROC-AUC	0.5958	0.5958
F1	0.7386	0.9424
Recall	0.6190	1.0000
Precision	0.9155	0.8910
Accuracy	0.61	0.89

Matriz de Confusión

Clase (Real vs. Pred.)	Umbral = 0.5	Umbral Óptimo
Real 0 → Pred. 0 (Verdaderos Negativos)	1201	0
Real 0 → Pred. 1 (Falsos Positivos)	1053	2254
Real 1 → Pred. 0 (Falsos Negativos)	7020	0
Real 1 → Pred. 1 (Verdaderos Positivos)	11403	18423

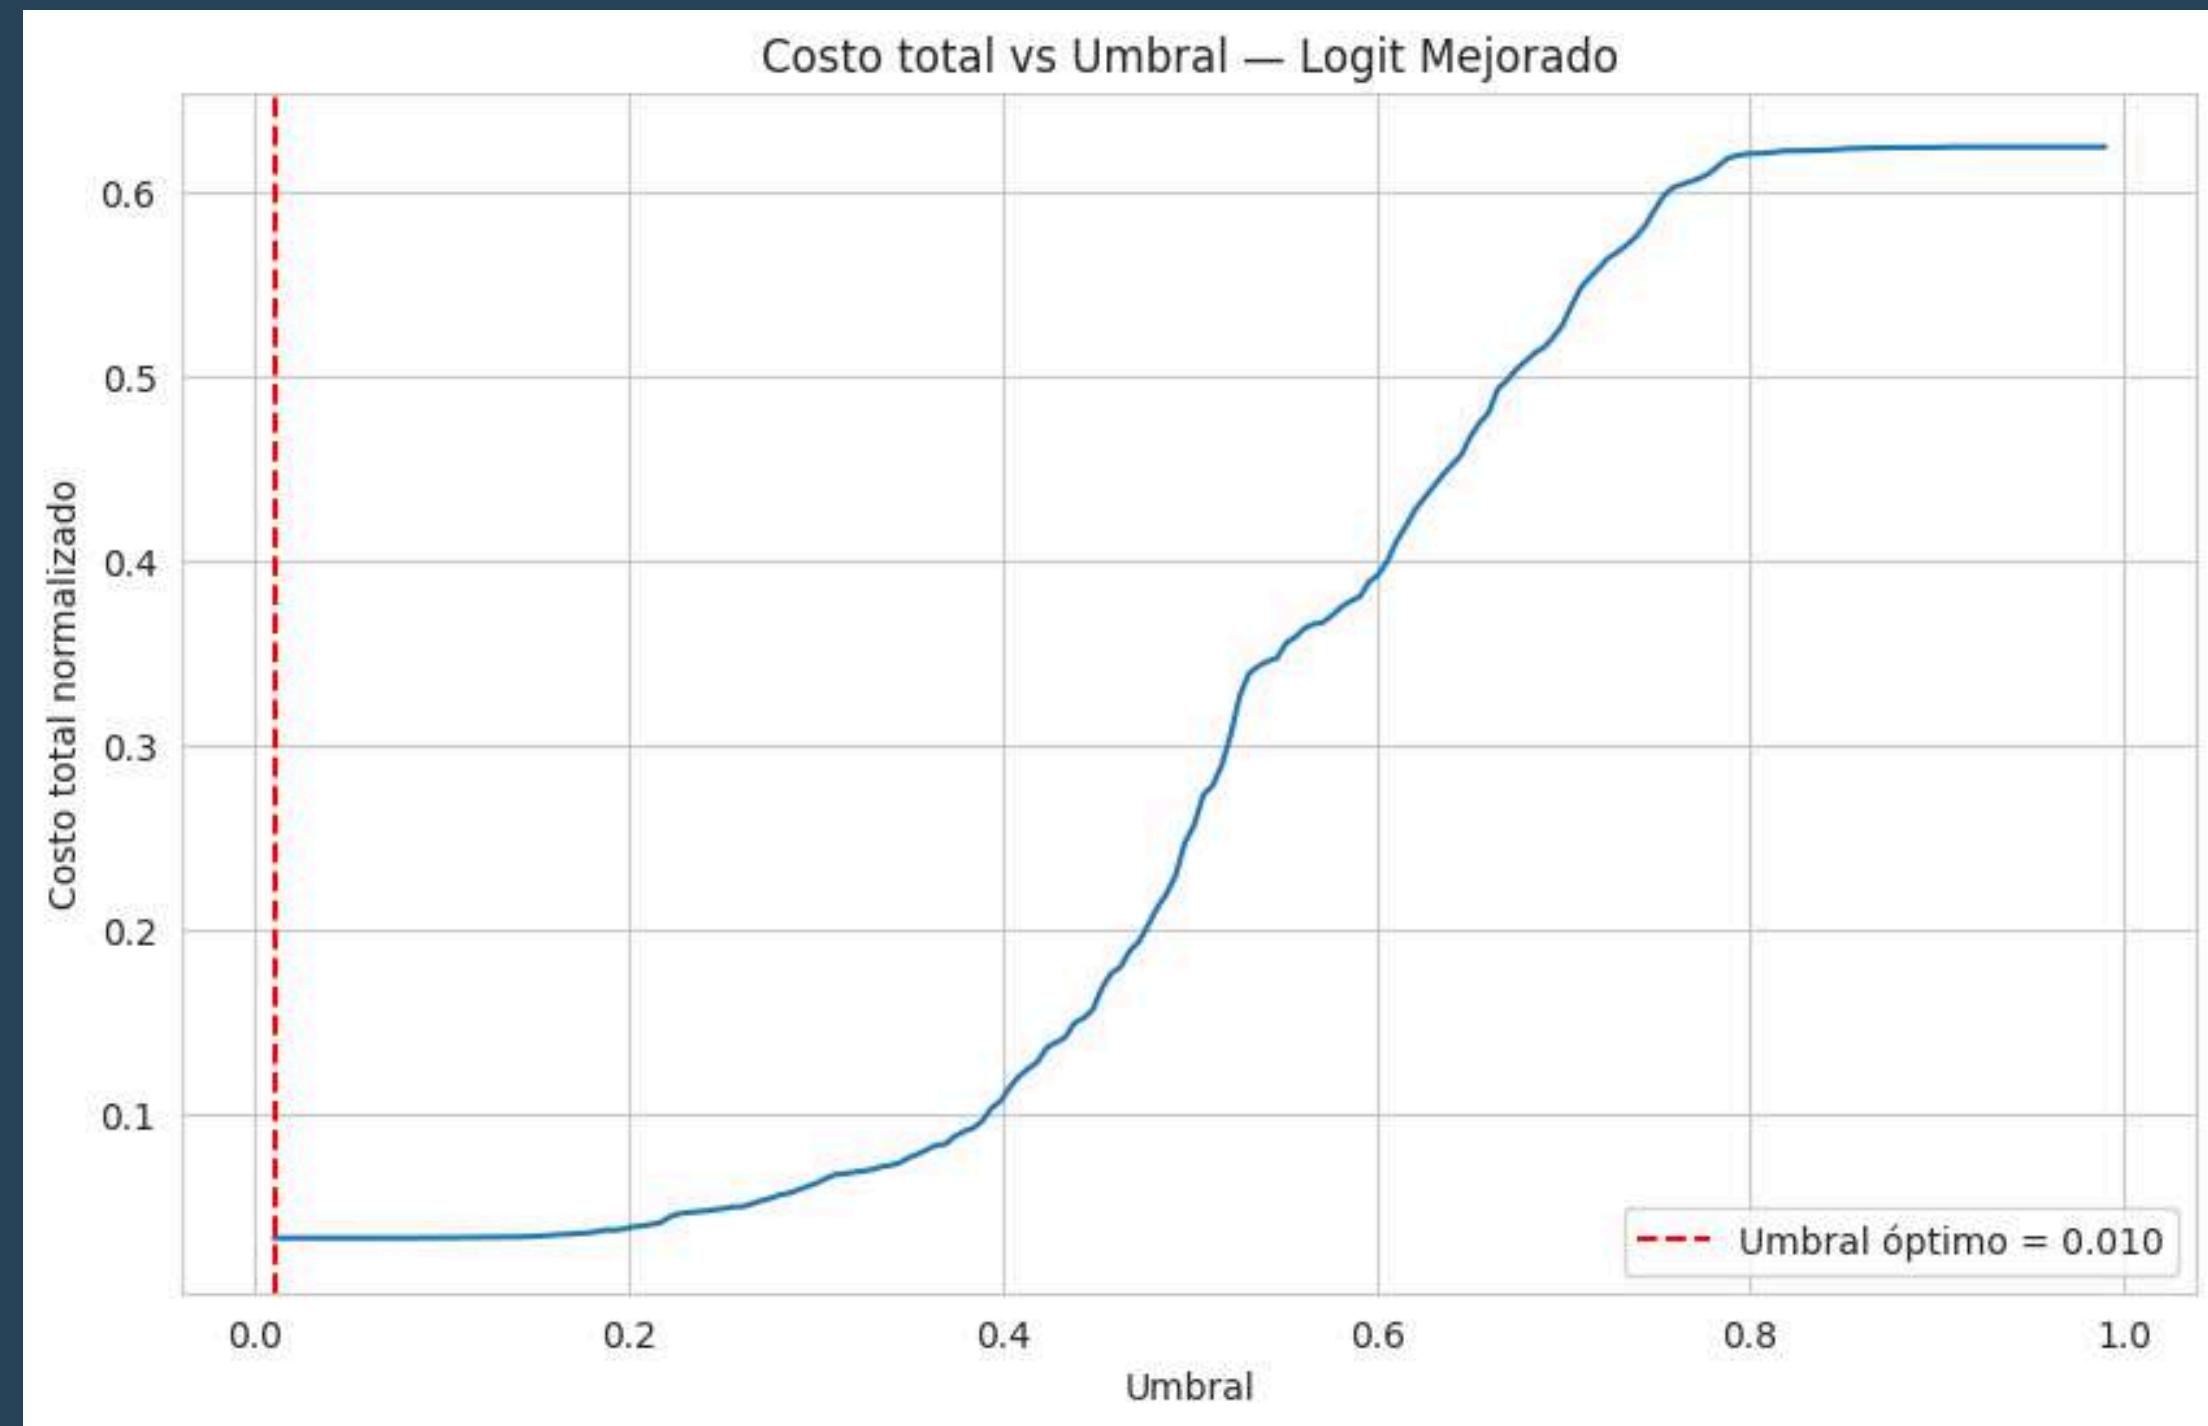


Figura 7: Costo Total vs Umbral



Grupo 5

XBOOST Y UMBRAL

El XGBoost es el modelo de alta potencia que se usa para asegurarse de que la predicción sea lo más precisa posible, y para confirmar la jerarquía de los factores de riesgo.





Table 2: Comparación de Métricas del Modelo XGBoost por Umbral

Métrica	Umbral Óptimo	Umbral = 0.5
PR-AUC	0.9187	0.9187
ROC-AUC	0.5966	0.5966
F1	0.9424	0.7686
Recall (Clase 1)	1.0000	0.6642
Precision (Clase 1)	0.8910	0.9118
Accuracy	0.89	0.64

Matriz de Confusión

Clase (Real vs. Pred.)	Umbral Óptimo	Umbral = 0.5
Real 0 → Pred. 0 (Verdaderos Negativos)	0	1070
Real 0 → Pred. 1 (Falsos Positivos)	2254	1184
Real 1 → Pred. 0 (Falsos Negativos)	0	6186
Real 1 → Pred. 1 (Verdaderos Positivos)	18423	12237

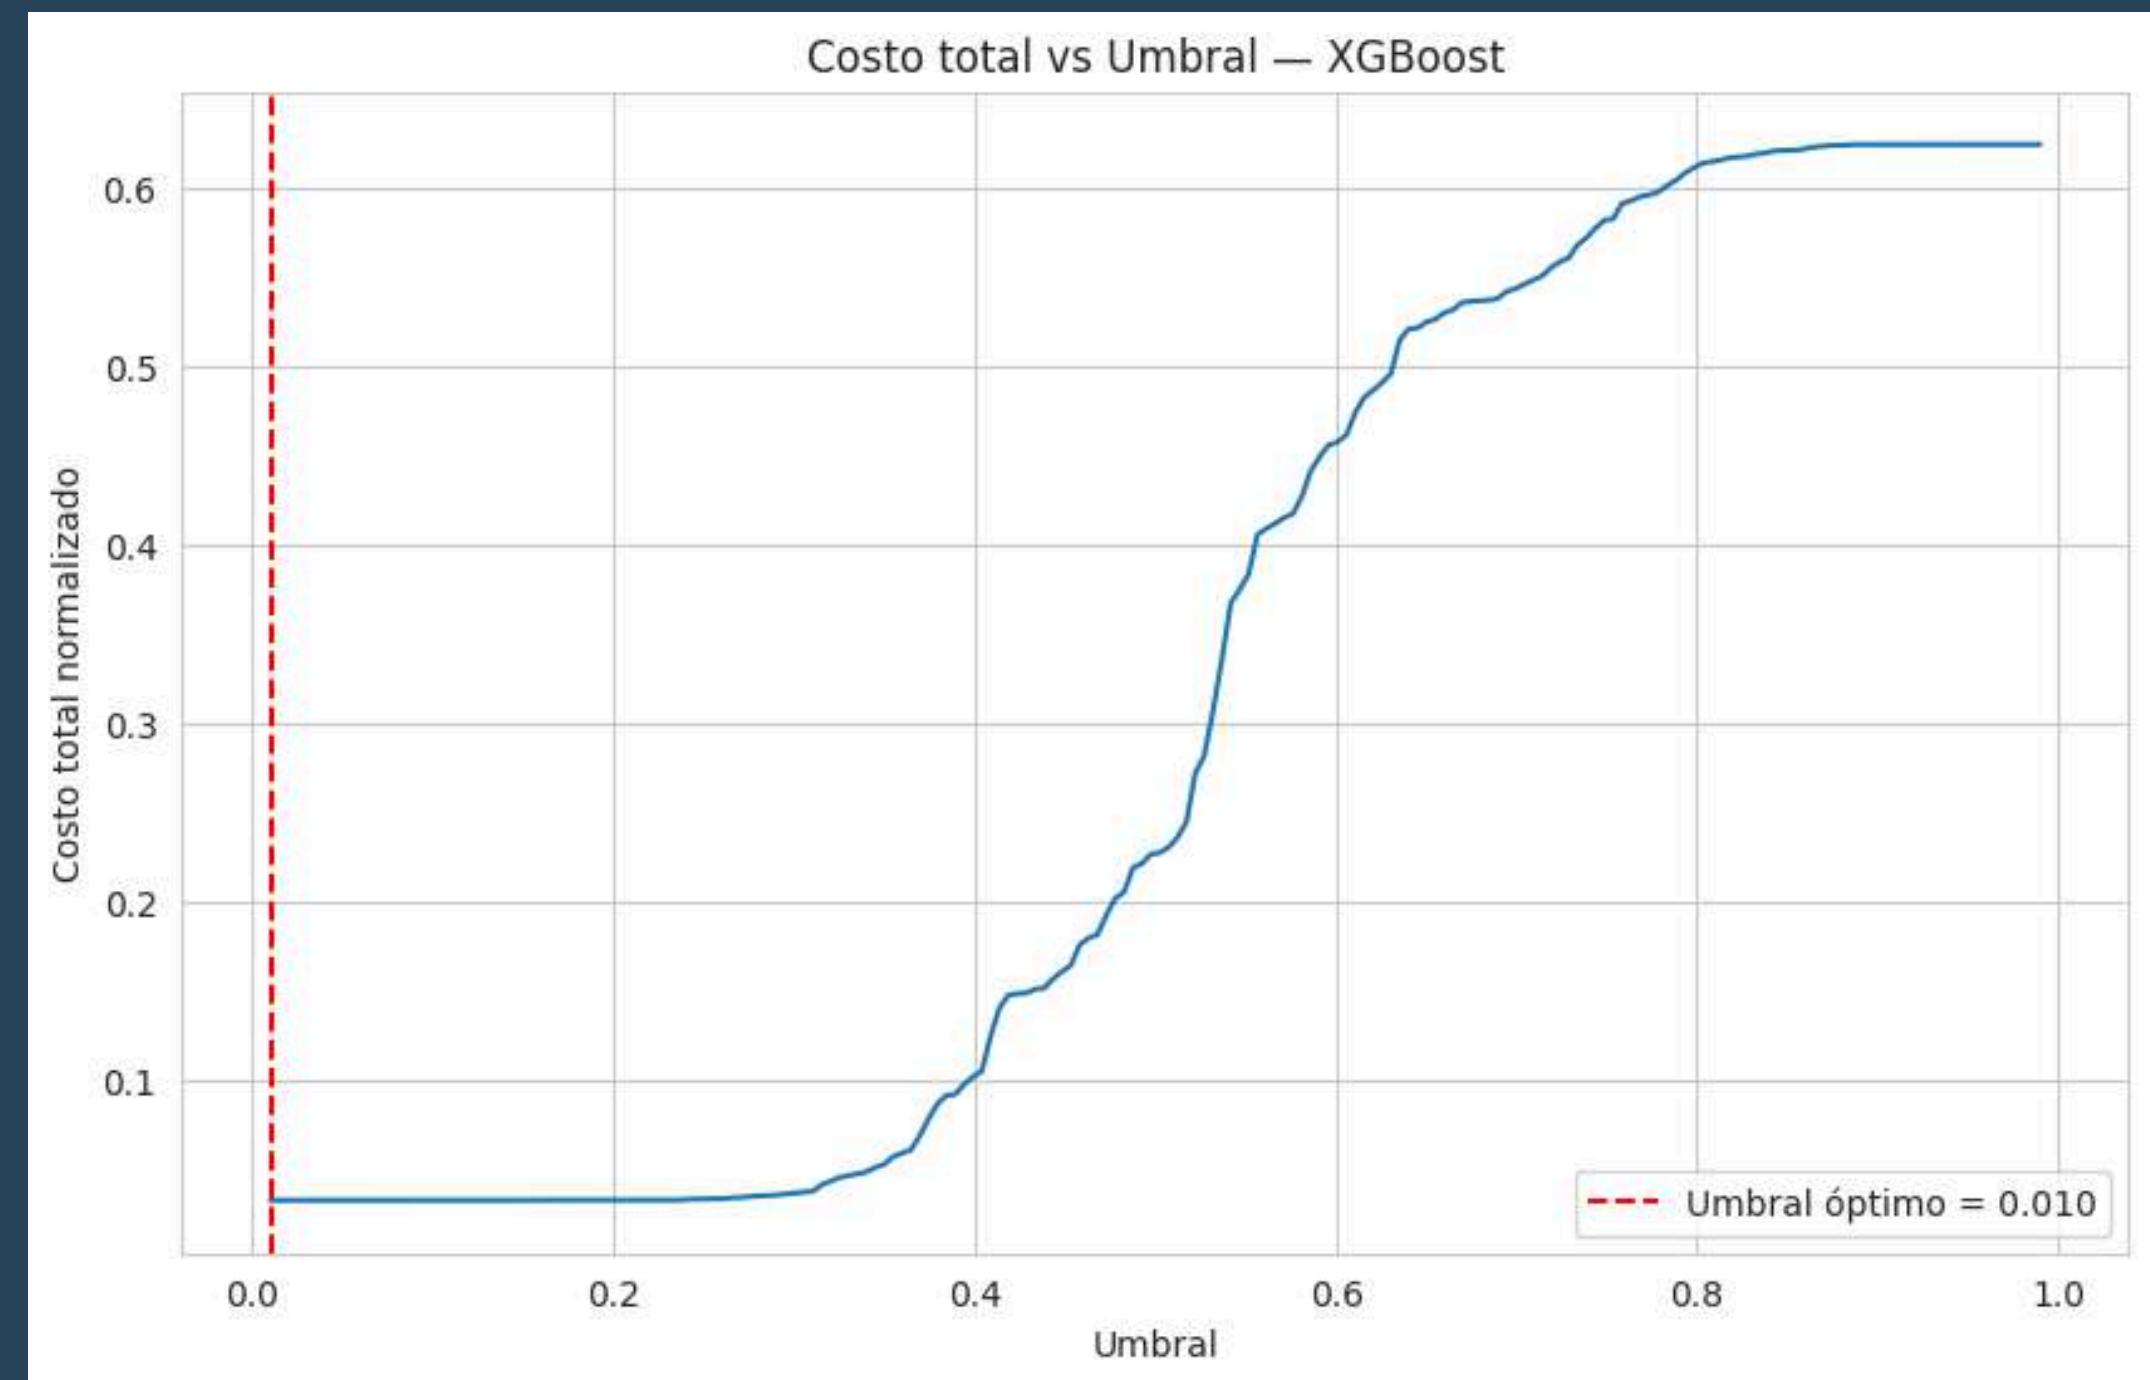


Figura 8: Costo Total vs Umbral

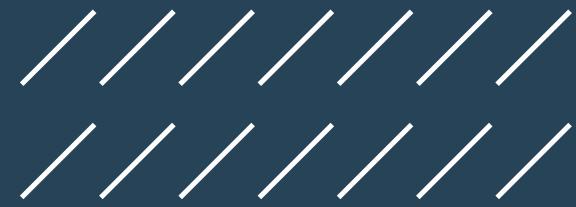
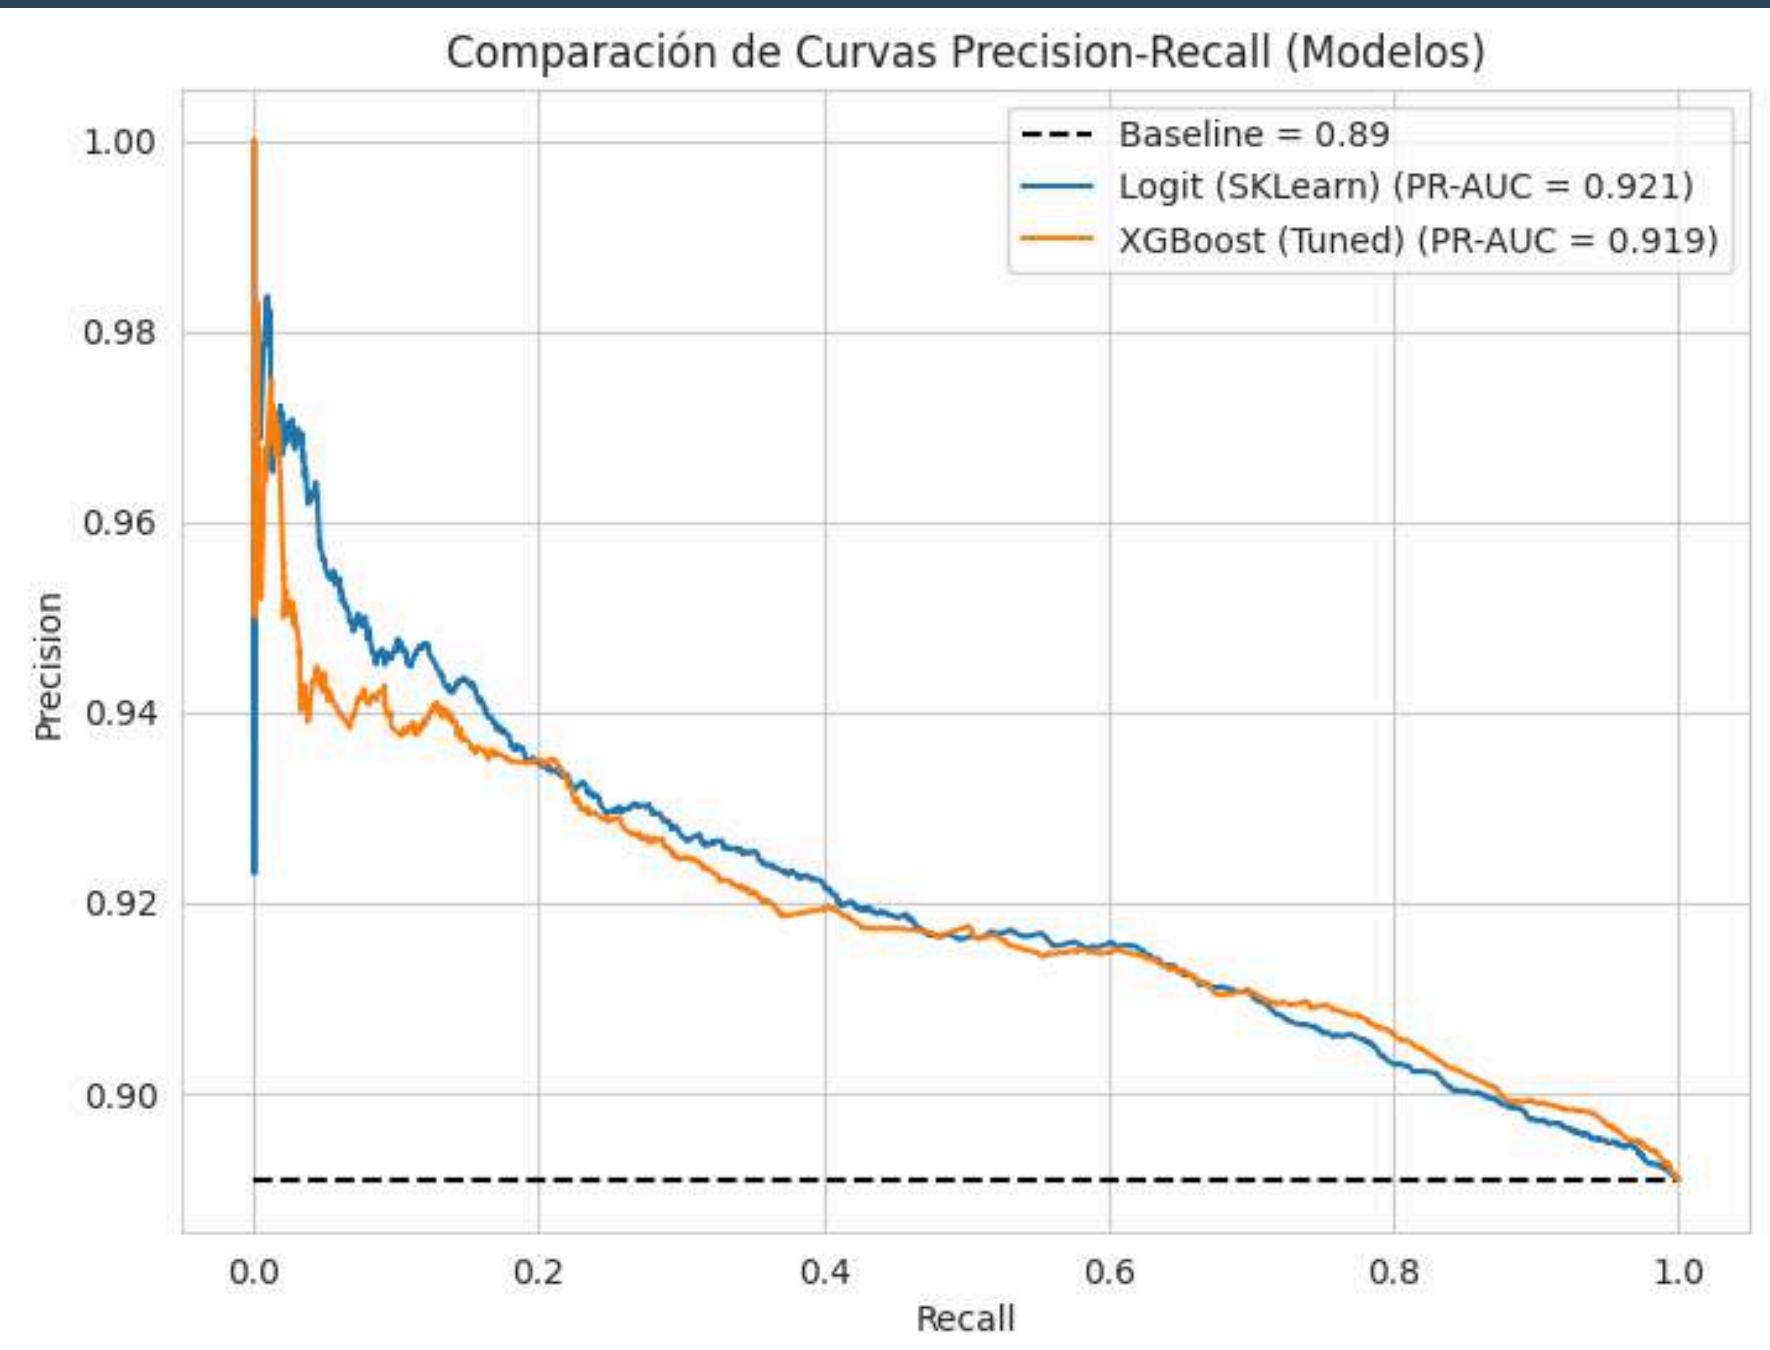
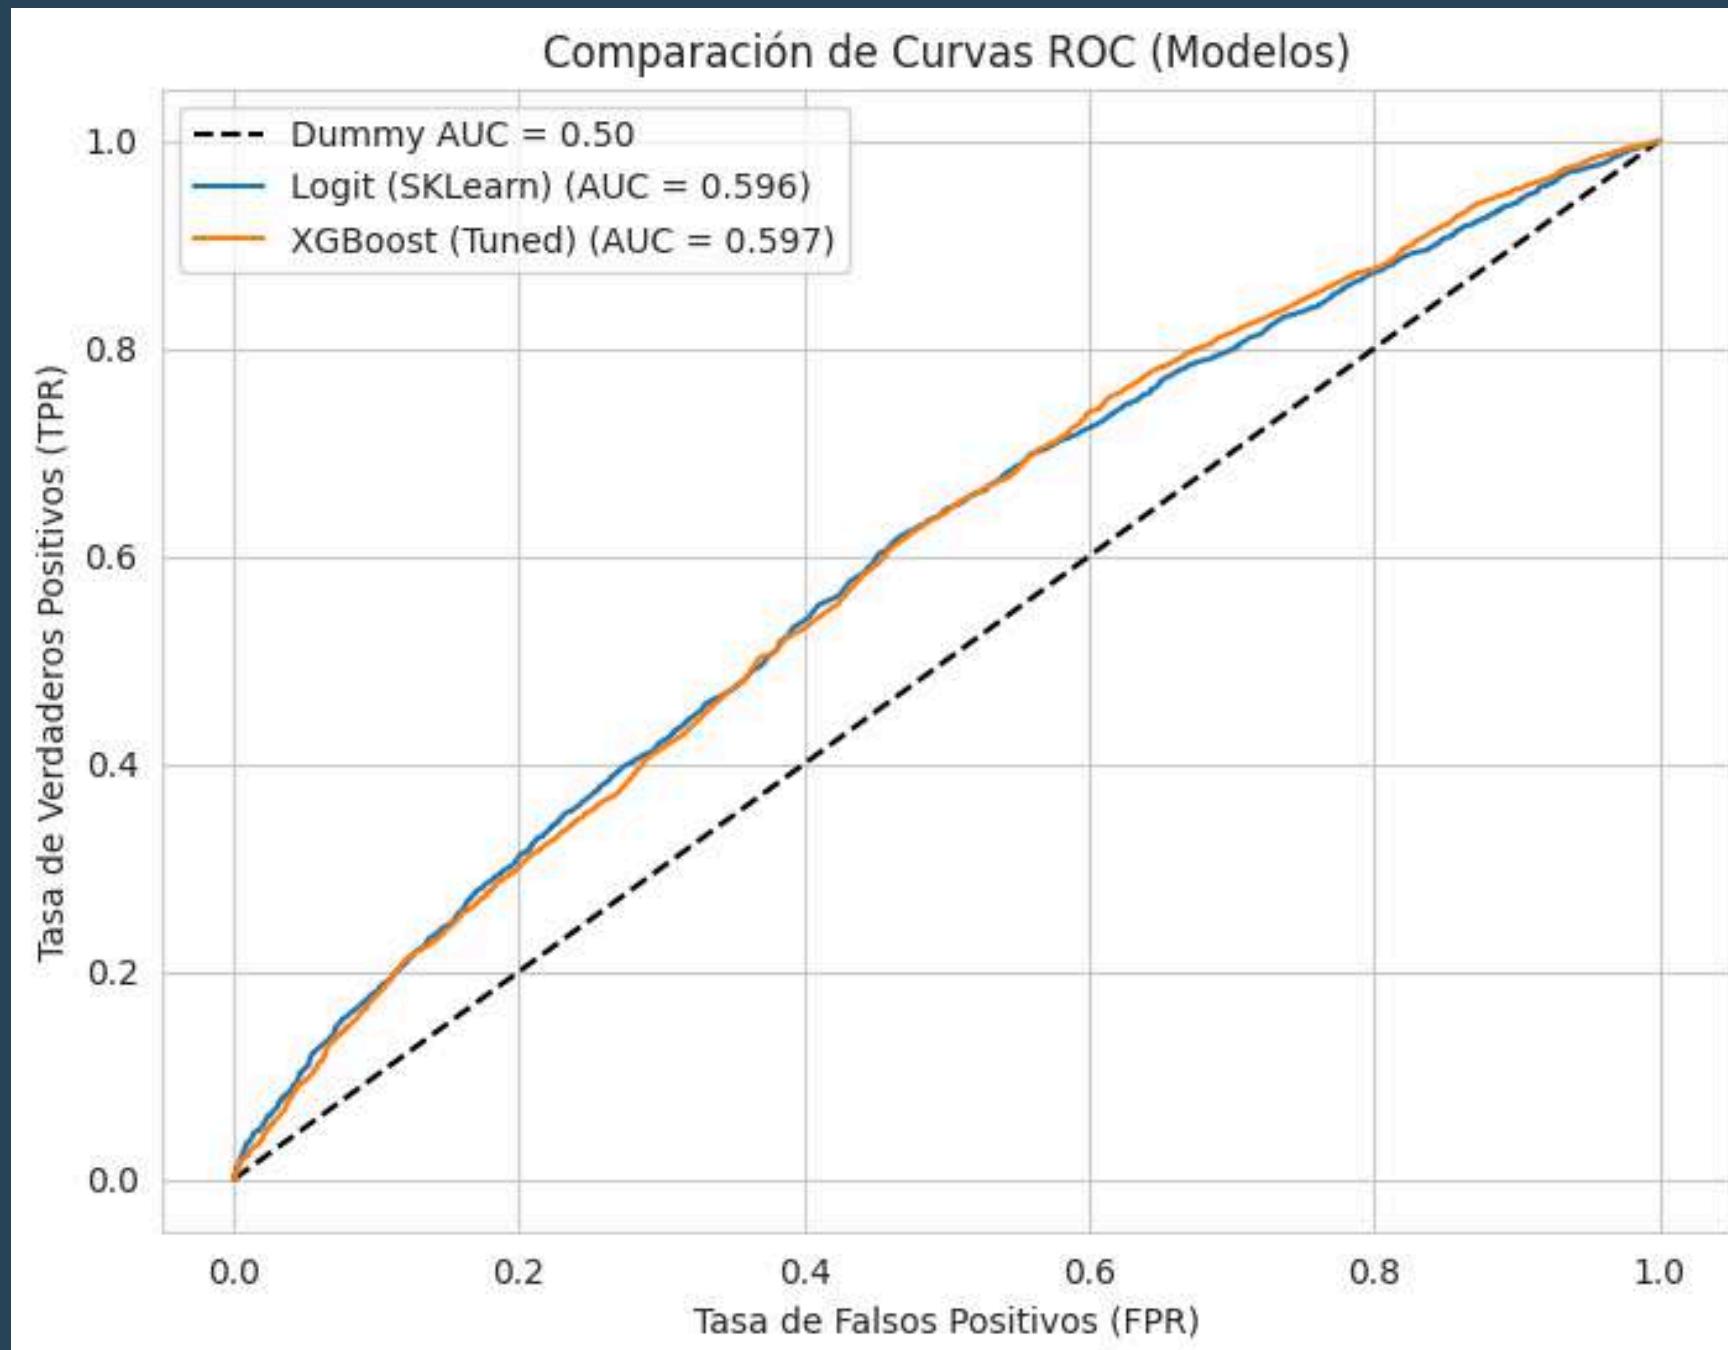


Table 3: Comparación de Modelos: Rendimiento con Umbral Óptimo

Métrica	Logit Mejorado	XGBoost
F1	0.9424	0.9424
Recall (Clase 1)	1.0000	1.0000
Precision (Clase 1)	0.8910	0.8910
ROC-AUC	0.5958	0.5966
PR-AUC	0.9205	0.9187
Accuracy	0.89	0.89
Macro Avg F1	0.47	0.47
Recall (Clase 0)	0.00	0.00





DAG EXPLÍCITO

El DAG propone que el acceso adecuado a controles prenatales depende directamente de factores estructurales como nivel de riqueza, educación, edad y área urbana, que influyen en la capacidad real de una gestante para acceder a servicios de salud.





DAG Causal del Acceso a Controles Prenatales

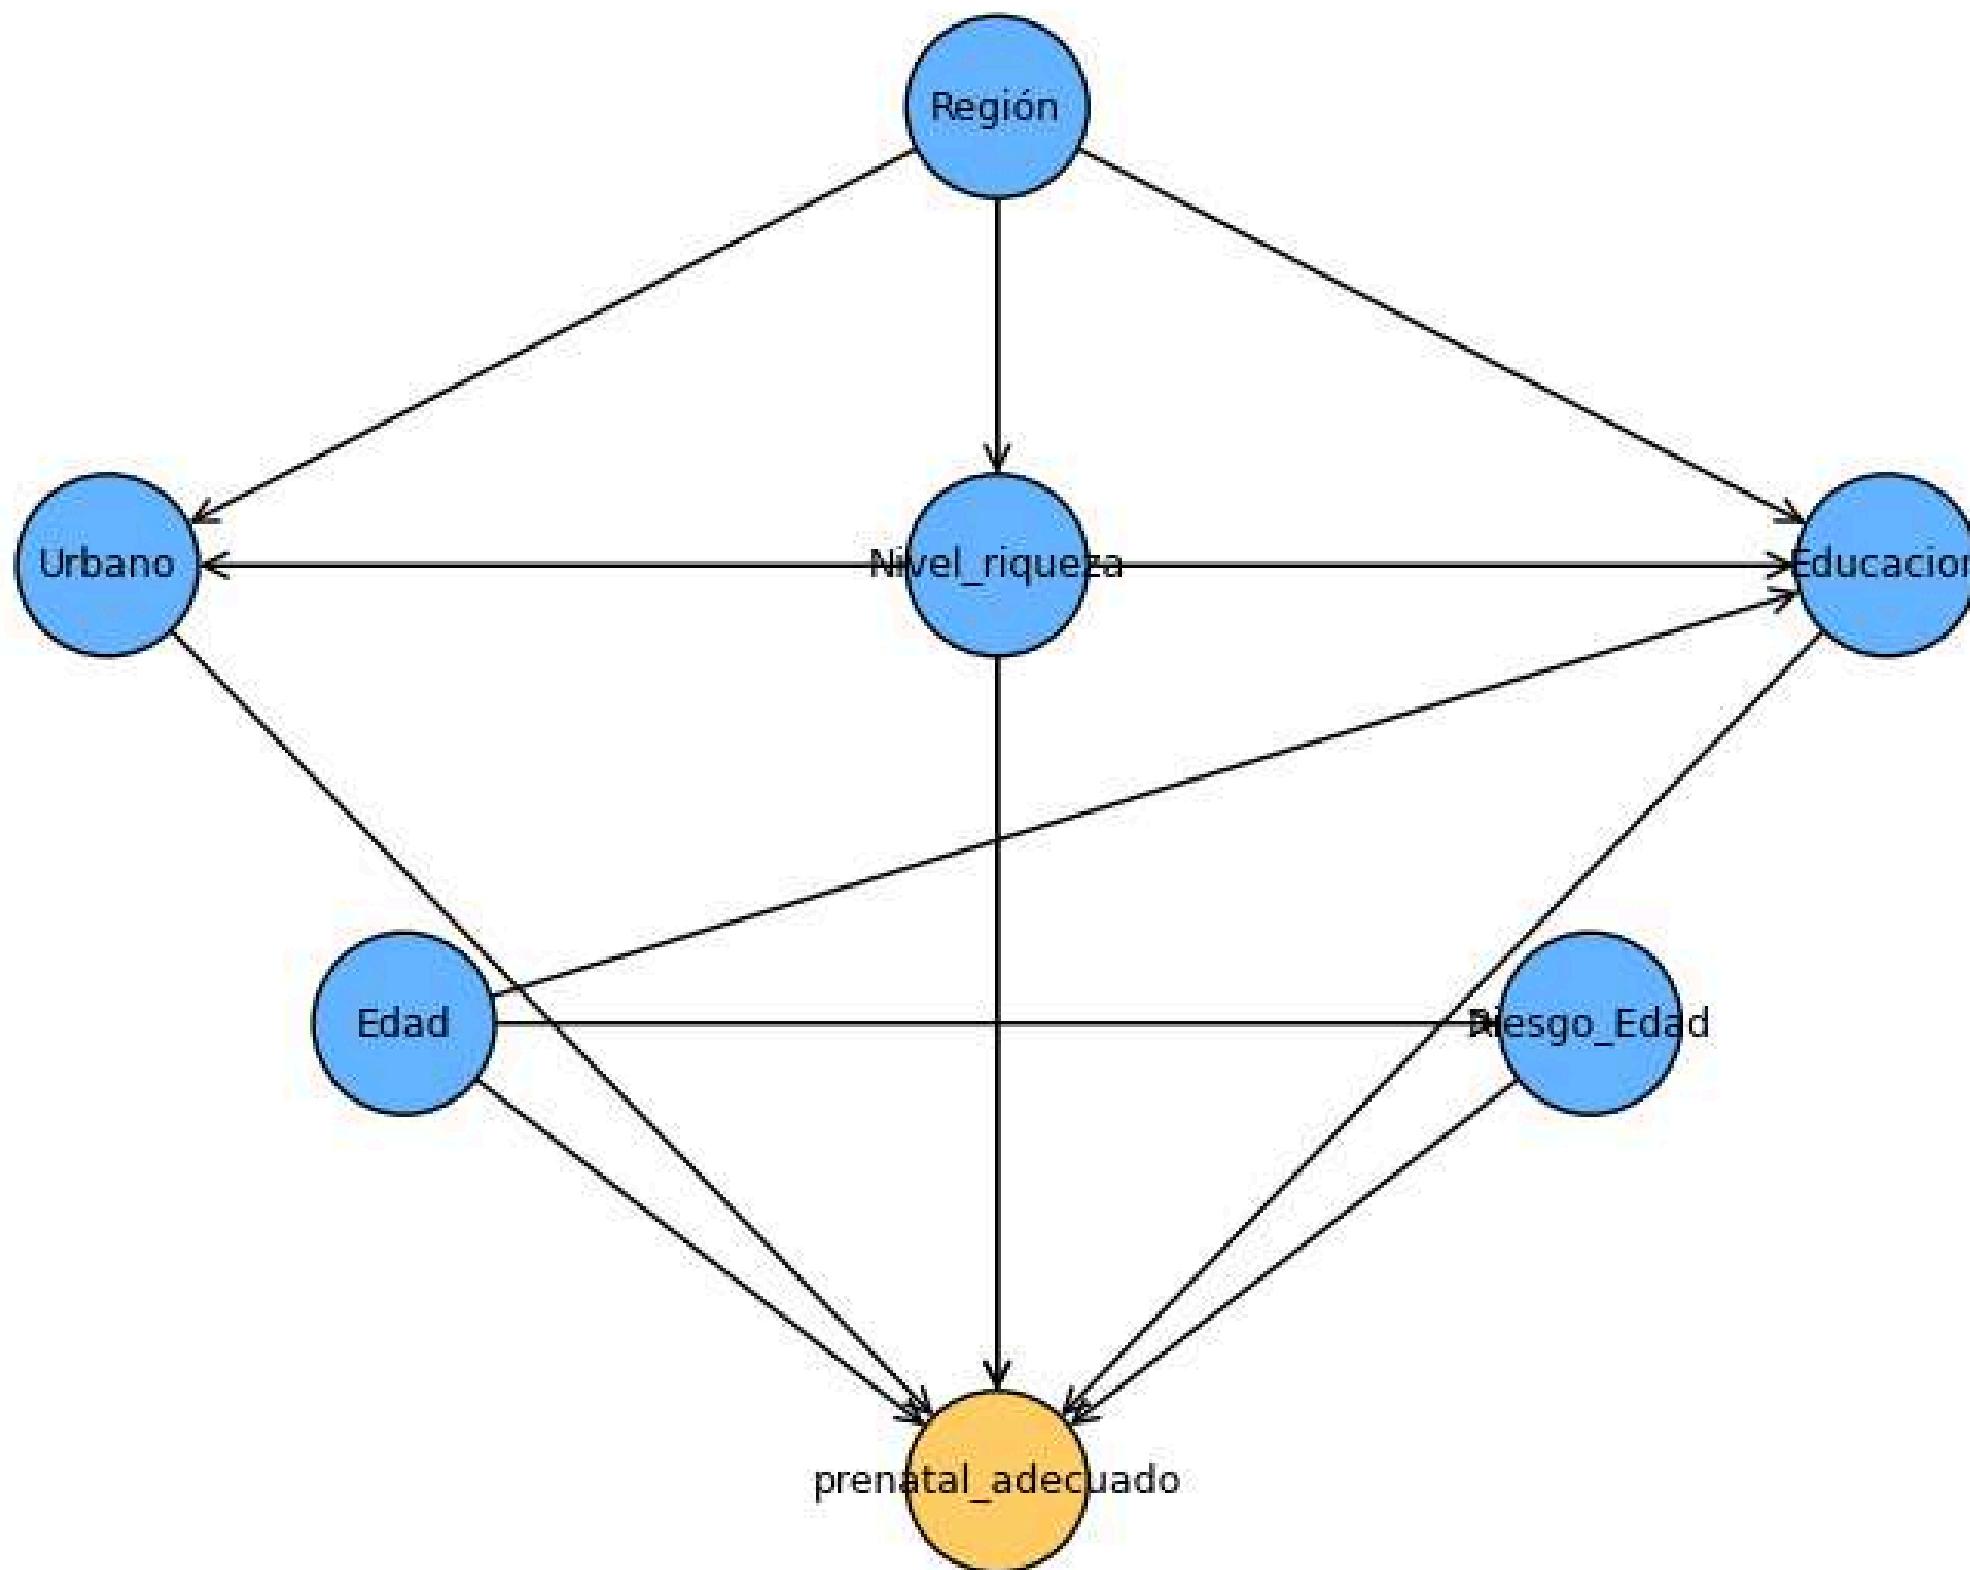


Figura 6: DAG CAUSAL

REDES NEURONALES





```
== MÉTRICAS DEL MLP ==
```

```
ROC-AUC: 0.6004
```

```
PR-AUC: 0.9176
```

```
F1: 0.9424
```

```
Precision: 0.8911
```

```
Recall: 0.9999
```

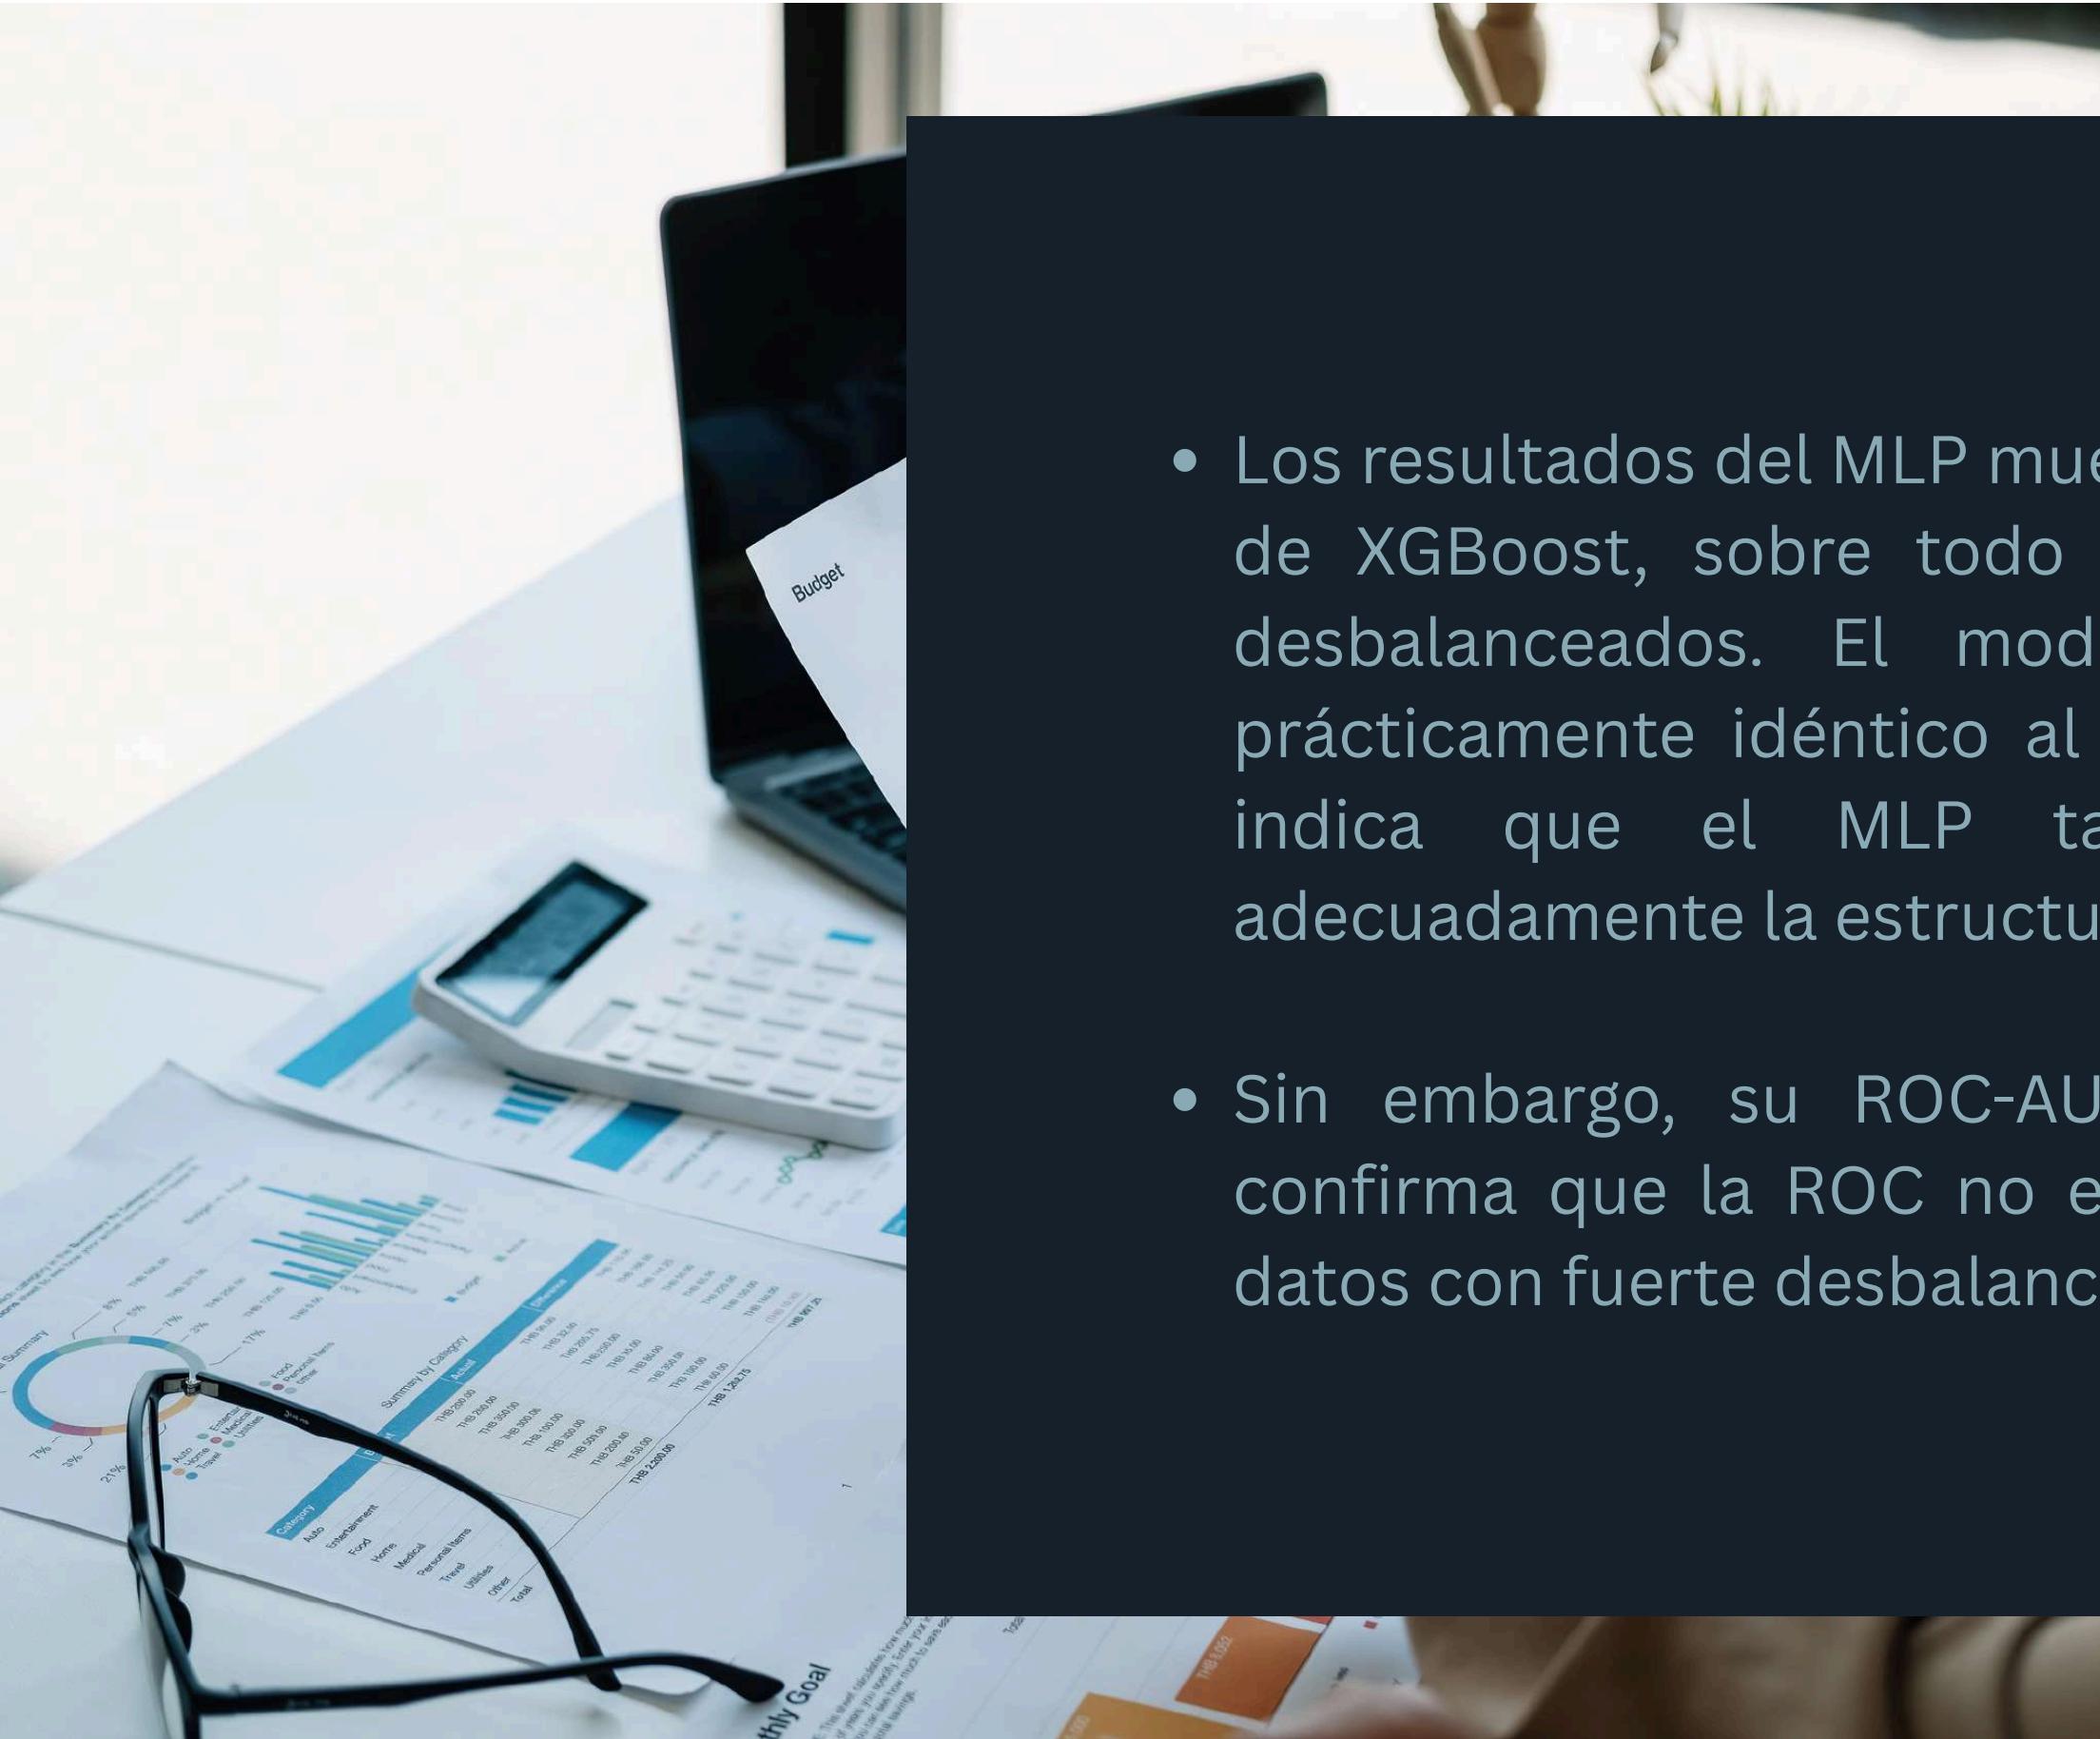
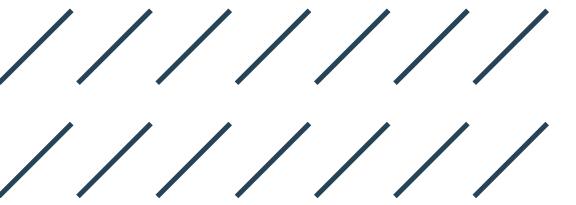
```
Matriz de Confusión:
```

```
[[ 2 2252]
 [ 1 18422]]
```

```
Reporte:
```

	precision	recall	f1-score	support
0	0.67	0.00	0.00	2254
1	0.89	1.00	0.94	18423
accuracy			0.89	20677
macro avg	0.78	0.50	0.47	20677
weighted avg	0.87	0.89	0.84	20677

Figura 6: Métricas y matriz de confusión



- Los resultados del MLP muestran un desempeño muy similar al de XGBoost, sobre todo en métricas robustas para datos desbalanceados. El modelo logra un PR-AUC = 0.918, prácticamente idéntico al mejor modelo del trabajo, lo que indica que el MLP también es capaz de capturar adecuadamente la estructura subyacente del problema.
- Sin embargo, su ROC-AUC (0.600) es moderado, lo que confirma que la ROC no es una métrica útil en este tipo de datos con fuerte desbalance.

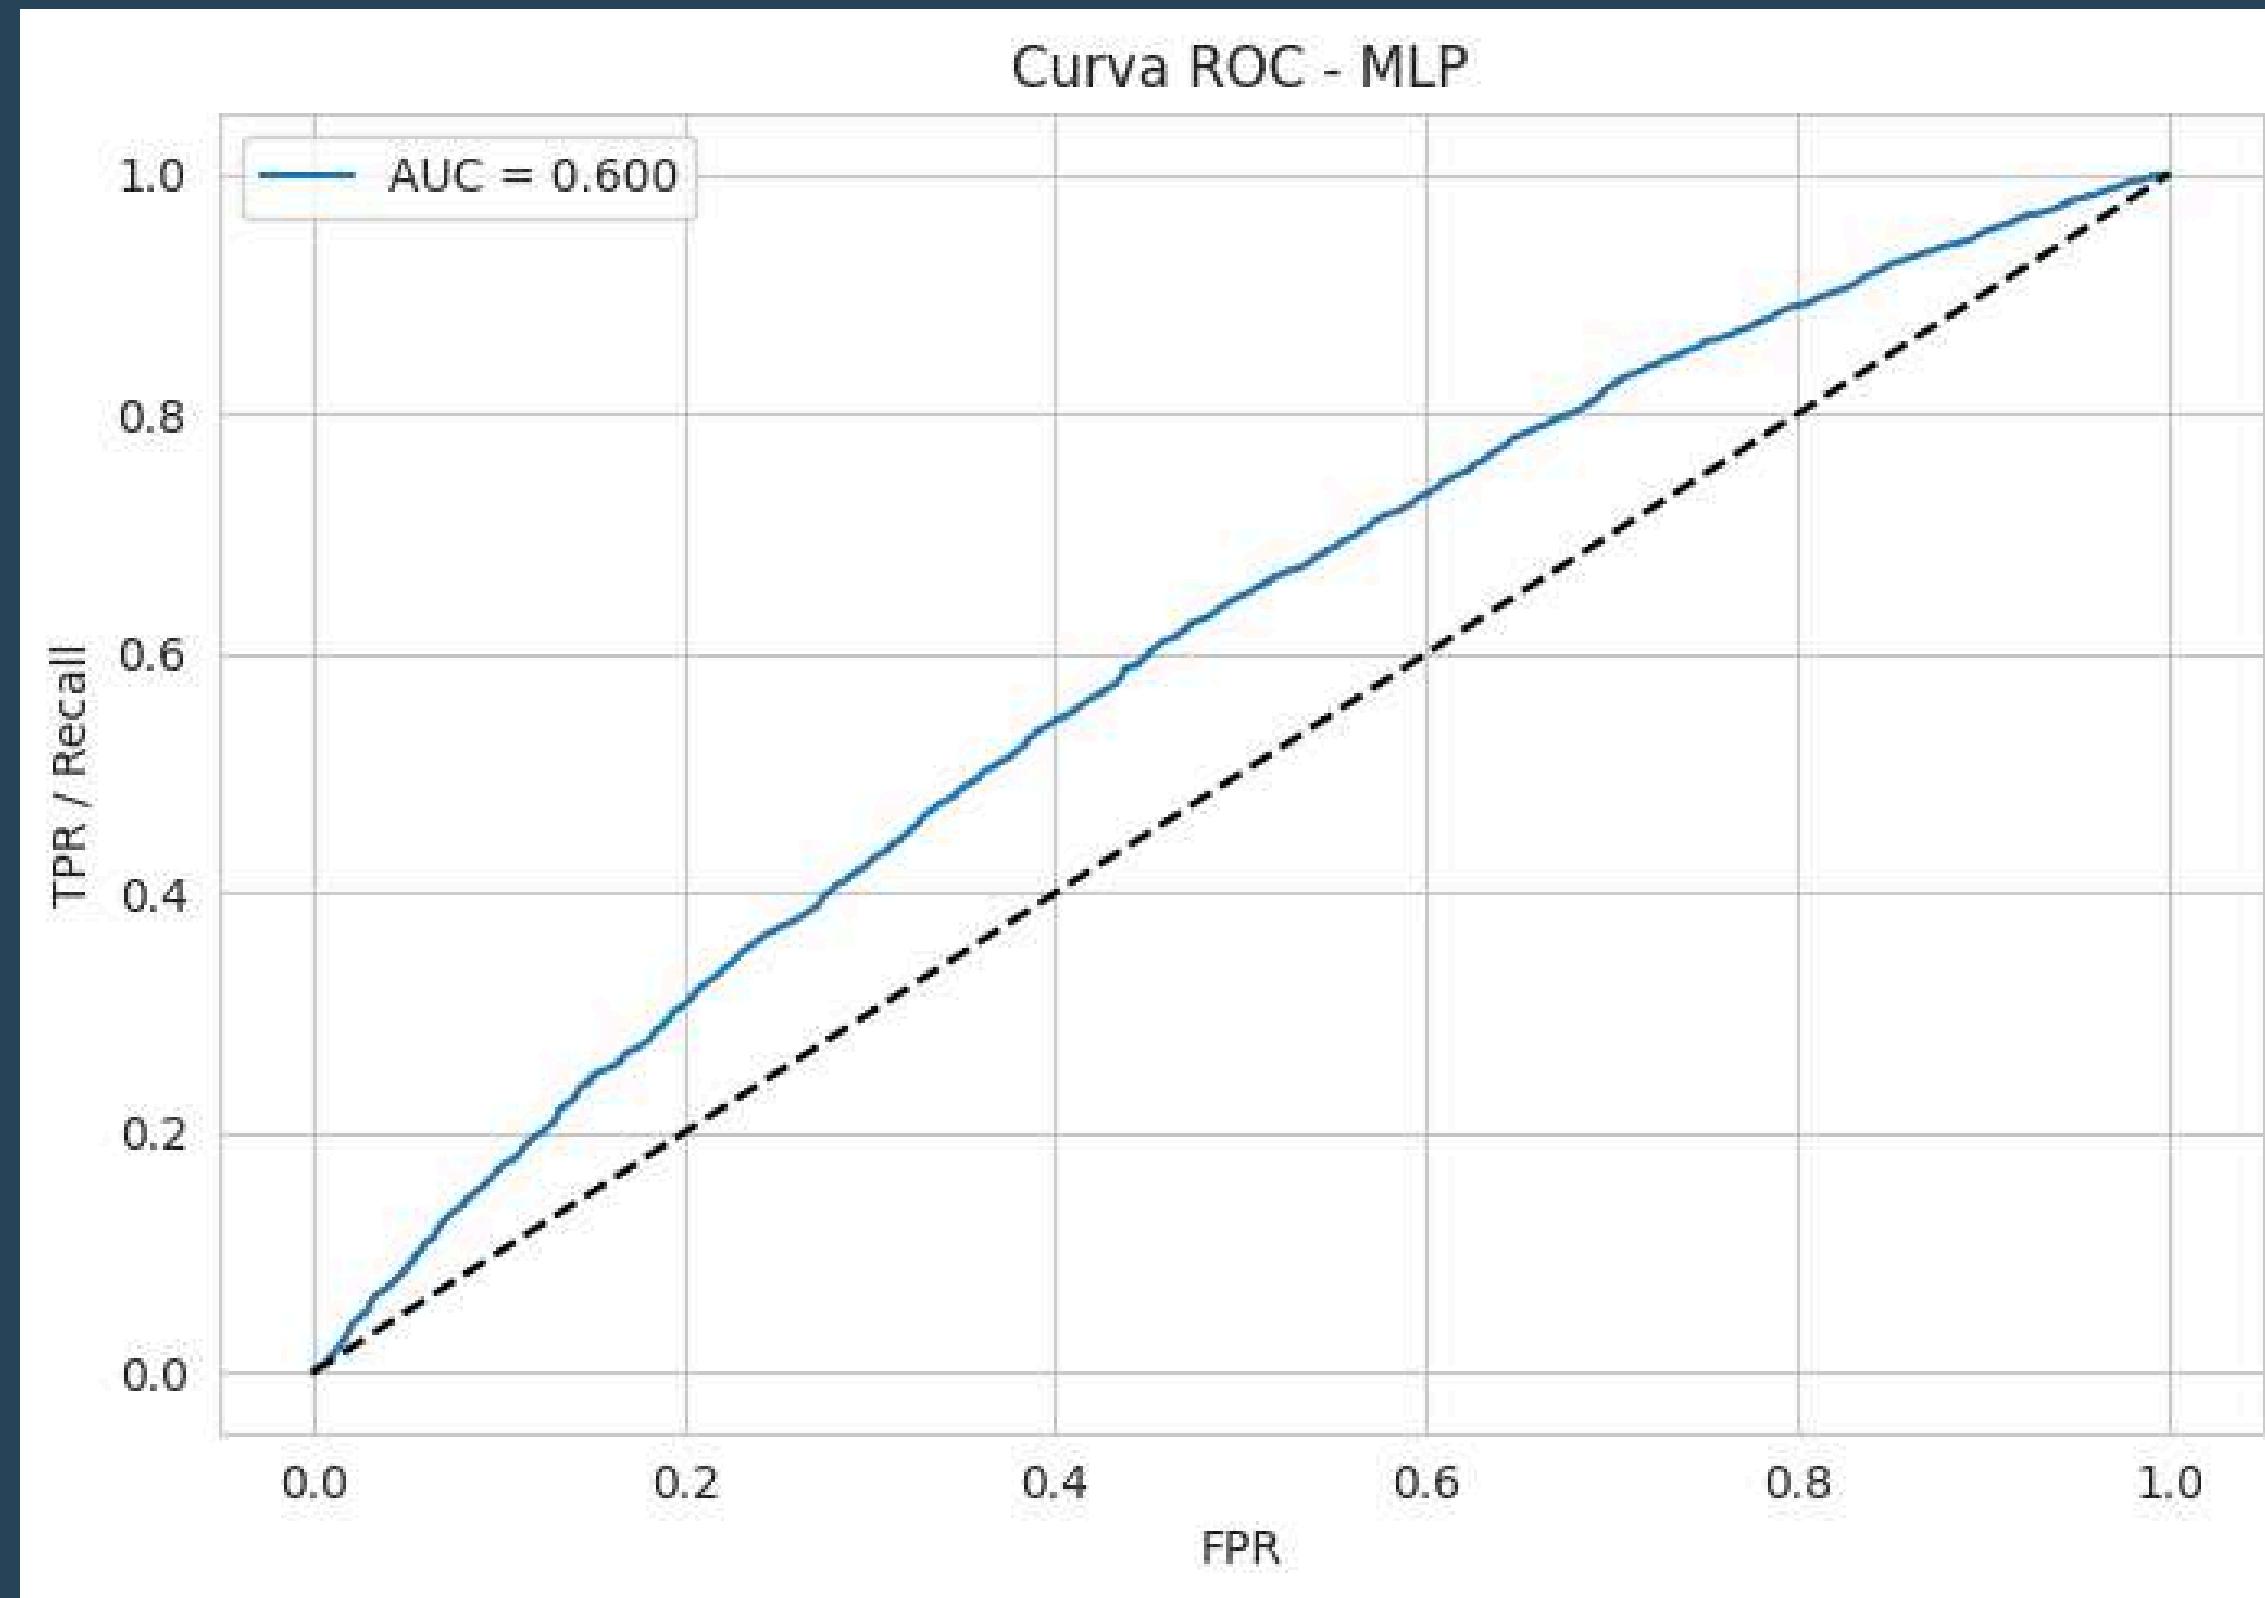


Figura 6: Curva ROC - MLP

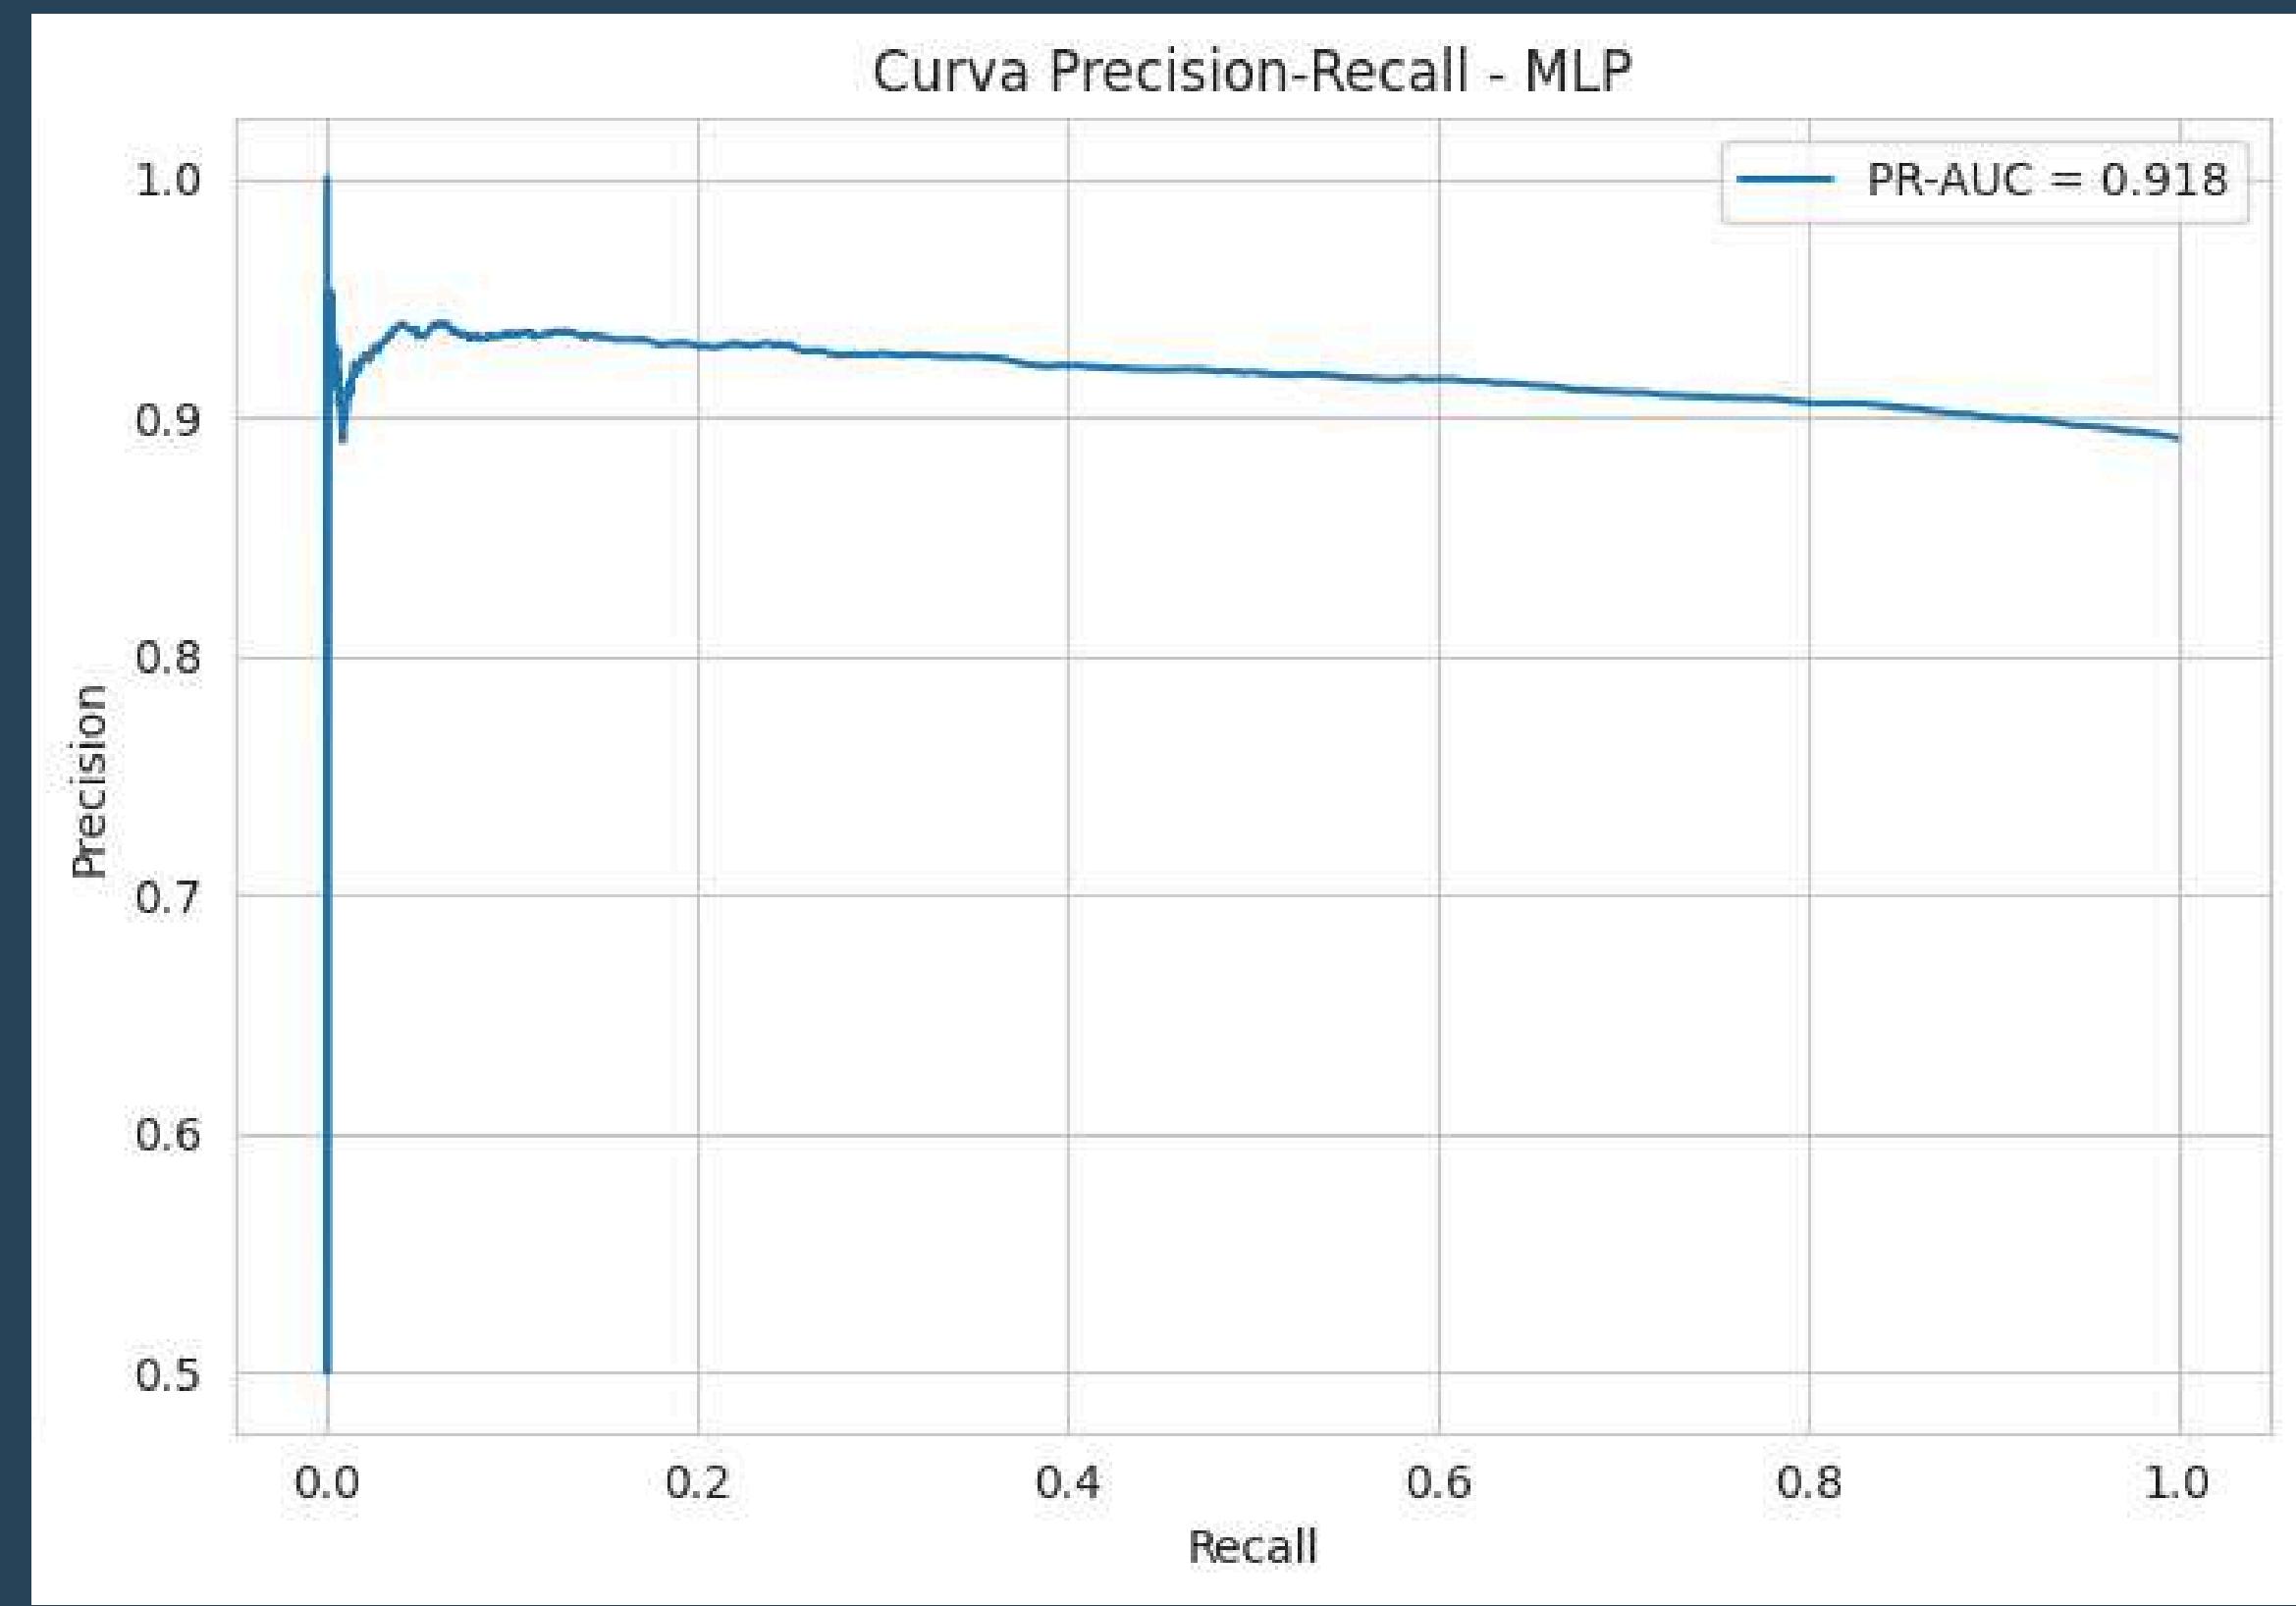
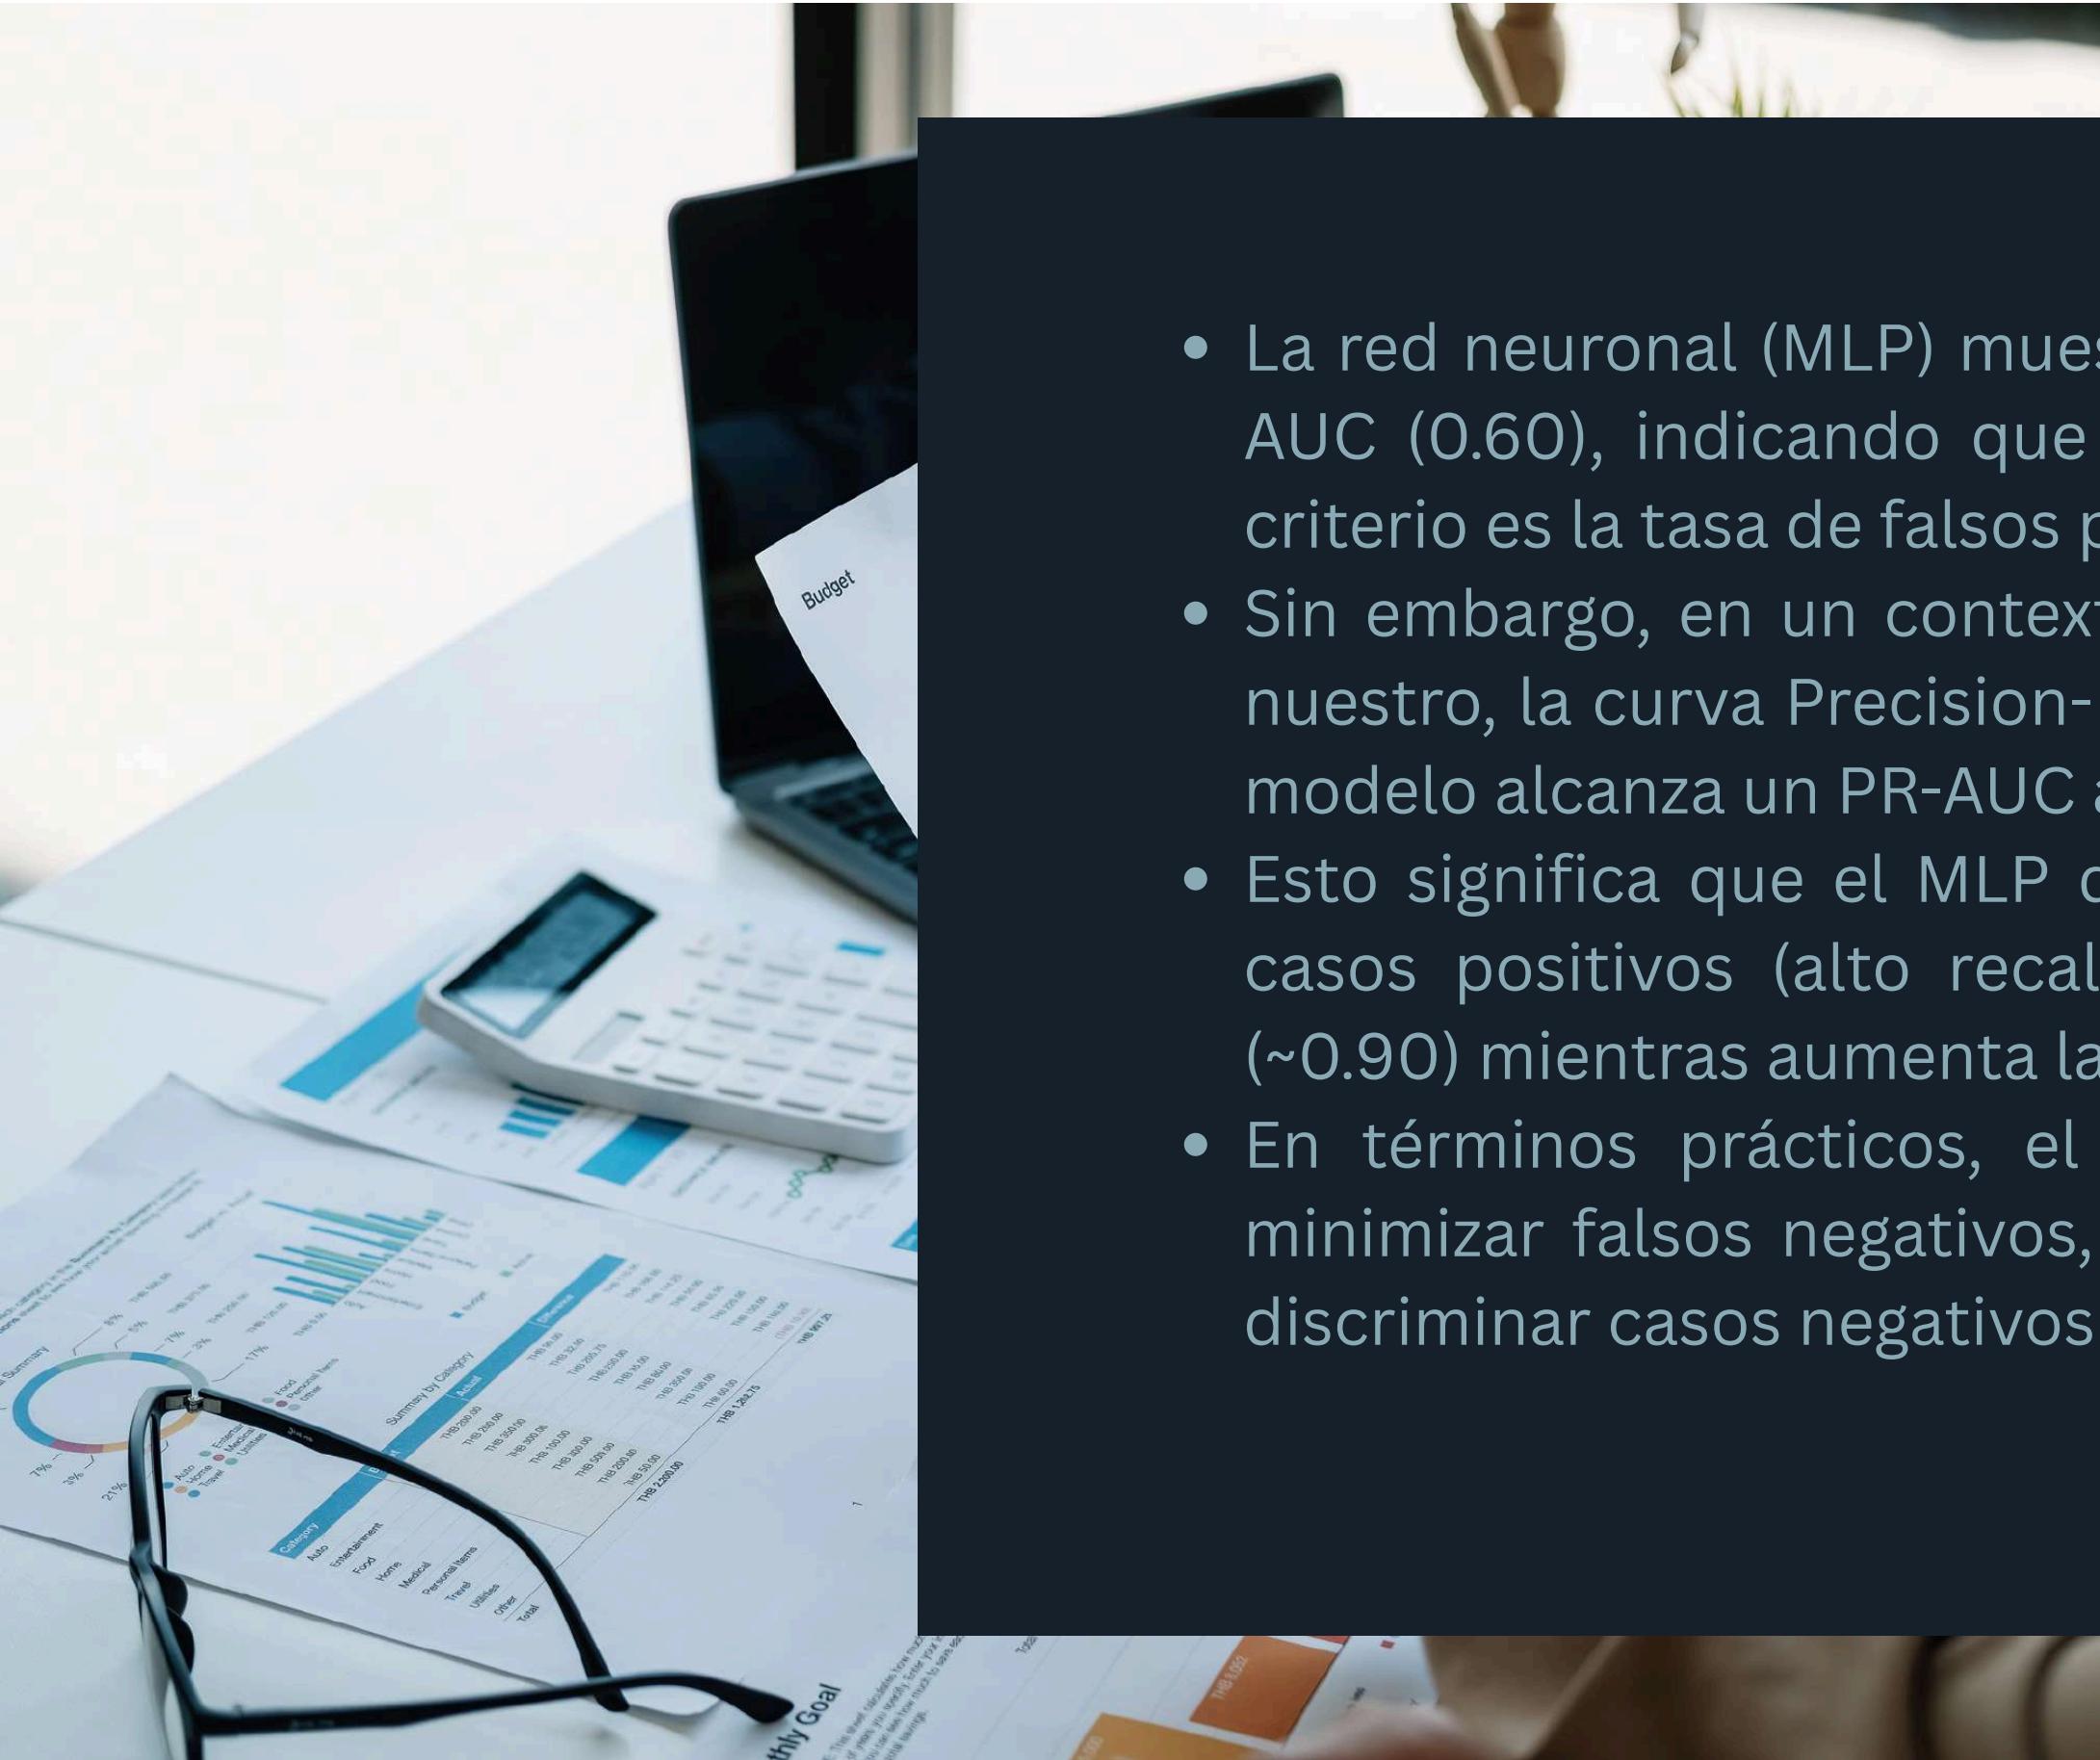
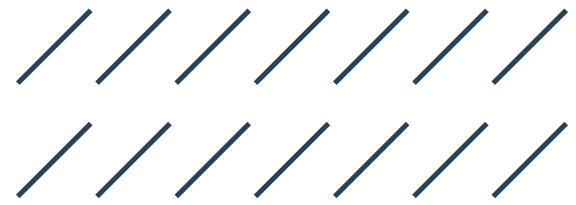


Figura 6: Curva MLP



- La red neuronal (MLP) muestra un desempeño modesto en ROC-AUC (0.60), indicando que no separa bien las clases cuando el criterio es la tasa de falsos positivos.
- Sin embargo, en un contexto altamente desbalanceado como el nuestro, la curva Precision-Recall es mucho más informativa, y el modelo alcanza un PR-AUC alto (0.918).
- Esto significa que el MLP detecta correctamente casi todos los casos positivos (alto recall) y mantiene una precisión estable (~0.90) mientras aumenta la sensibilidad.
- En términos prácticos, el MLP es útil cuando el objetivo es minimizar falsos negativos, pero aún presenta limitaciones para discriminar casos negativos (reflejadas en el ROC).



Gracias

Fabricio Calle Cardoza \\\ Bianca Nicole Jimenez
Vargas \\\ Aracely Lalupu Lalupu \\\ Jose Alonso Naira
Carmen.

